

Clasificación de gestos de mano mediante señales EMG utilizando redes LSTM

De Mónica Monserrat Martínez Vásquez | A01710965

Desarrollo de aplicaciones avanzadas de ciencias computacionales (Gpo 302)

Fecha: 04/06/2026

1. INTRODUCCIÓN

La electromiografía superficial (sEMG) es una técnica ampliamente utilizada en biomecánica, neuroingeniería y rehabilitación para analizar la actividad eléctrica producida por los músculos durante la ejecución de diferentes movimientos. Su naturaleza multicanal, su alta variabilidad fisiológica y la presencia de ruido convierten la clasificación automática de gestos basados en EMG en un problema desafiante que requiere métodos de procesamiento avanzados capaces de capturar relaciones temporales y espaciales complejas dentro de la señal.

En los últimos años, las arquitecturas de aprendizaje profundo han demostrado un rendimiento superior en tareas relacionadas con la interpretación de bioseñales, gracias a su capacidad para aprender representaciones jerárquicas directamente a partir de los datos. Modelos como las redes LSTM, CNN y sus variantes híbridas han mostrado buenos resultados en la detección de patrones musculares no lineales, la identificación de movimientos específicos y la mejora de la robustez frente a la variabilidad de cada sujeto. En este contexto, la clasificación de gestos de la mano basados en señales EMG representa un caso de estudio relevante tanto para la investigación científica como para aplicaciones reales en interfaces humano-máquina, control de prótesis, rehabilitación asistida y tecnologías biomédicas emergentes.

El presente proyecto tiene como objetivo desarrollar, entrenar y comparar diferentes arquitecturas de deep learning para la clasificación de gestos a partir del dataset público “EMG Data for Gestures”, obtenido mediante el brazalete Myo Armband. Se implementaron cuatro modelos principales:

1. Una red LSTM unidireccional como línea base,
2. Un modelo híbrido CNN + LSTM para mejorar la extracción de características espaciales
3. Una arquitectura BiLSTM combinada con técnicas de data augmentation y rebalanceo de clases, diseñada para abordar directamente las deficiencias observadas en los experimentos iniciales.

4. Una arquitectura CNN + BiLSTM + Attention, diseñada para integrar extracción espacial, modelado temporal bidireccional y selección automática de los instantes más relevantes de cada ventana EMG.

Cada modelo fue entrenado y evaluado utilizando un pipeline completo de preparación de datos, segmentación mediante ventanas deslizantes por archivo, normalización ajustada únicamente con el conjunto de entrenamiento, partición por archivo y evaluación independiente en validación y prueba. Adicionalmente, durante el análisis de las curvas de pérdida y precisión se observó un comportamiento progresivo y estable, lo que sugiere que un mayor número de épocas habría permitido continuar mejorando el desempeño de los modelos. Sin embargo, debido a las limitaciones computacionales de los dispositivos y GPUs disponibles durante el entrenamiento, se estableció un máximo de 200 épocas como límite. A pesar de ello, los modelos lograron converger adecuadamente y mostrar mejoras.

A lo largo del reporte se documentan los fundamentos, la metodología de implementación, los análisis comparativos y las conclusiones derivadas del proceso experimental.

Durante el desarrollo del proyecto también se identificó y corrigió un problema metodológico relacionado con data leakage. En las primeras versiones del pipeline, algunas etapas podían permitir que información indirecta del conjunto de prueba influyera en el entrenamiento, por ejemplo al normalizar antes de dividir los datos, aplicar augmentation antes del split o dividir ventanas solapadas de un mismo archivo entre entrenamiento y prueba. Por ello, el pipeline final fue corregido para dividir por archivo, ajustar el StandardScaler solo con train y aplicar data augmentation únicamente sobre el conjunto de entrenamiento.

2. SELECCIÓN DEL DATASET

Para el desarrollo del presente proyecto se seleccionó el conjunto de datos público “EMG Data for Gestures”[1], disponible en la plataforma Kaggle. Este

dataset fue obtenido mediante el brazalete Myo Armband de la compañía Thalmic Labs, el cual cuenta con ocho sensores de electromiografía superficial (sEMG) puestos alrededor del antebrazo. Los datos representan la actividad eléctrica de los músculos durante la ejecución de diferentes gestos de la mano, tales como flexión, extensión, desviación radial y cubital, puño cerrado, palma extendida y mano relajada. Cada gesto se encuentra etiquetado mediante un número entero que se corresponde con las lecturas simultáneas de los ocho canales del brazalete.

La elección de este conjunto de datos responde a varios criterios técnicos y metodológicos. En primer lugar, se trata de un dataset real, multicanal y de alta resolución temporal, adecuado para evaluar la capacidad de modelos profundos como LSTM de capturar patrones fisiológicos complejos. En segundo lugar, los archivos se encuentran organizados por sesiones y sujetos en formato de texto plano (.txt), lo cual facilita su lectura, inspección y manipulación utilizando bibliotecas estándar de análisis de datos en Python. Adicionalmente, la clasificación de gestos musculares constituye un caso representativo de aplicaciones biomédicas reales, donde la interpretación de señales EMG es un reto ampliamente estudiado.

Cada archivo del conjunto contiene diez columnas: una columna temporal (time), ocho canales de señal EMG (ch1 a ch8) y una columna de etiqueta (label). Las señales fueron muestreadas a alta frecuencia, permitiendo capturar los cambios rápidos de la actividad muscular. En la mayoría de los casos, las etiquetas permanecen constantes durante la ejecución de un gesto, lo cual posibilita segmentar los datos en ventanas temporales homogéneas para su tratamiento como muestras supervisadas. Cabe destacar que, a diferencia de datasets simplificados, este conjunto de datos presenta ruido fisiológico y variabilidad intersujeto, lo que incrementa la complejidad.

Antes del procesamiento, se realizó una inspección de consistencia para verificar que todos los archivos cumplieran con el mismo formato de columnas y se descartaron aquellos con estructuras anómalas o etiquetas no válidas. Después, se contabilizaron los registros disponibles por clase, revisando la distribución de ejemplos por gesto, lo cual permitió definir una partición por archivo con verificación de presencia de clases en entrenamiento, validación y prueba.

3. PREPARACIÓN DE DATOS

El conjunto de datos seleccionado consistía en múltiples archivos de texto plano que contenían registros secuenciales de señales EMG multicanal recopiladas

mediante el sensor Myo Armband. Debido a la naturaleza fisiológica de las señales, se diseñó un proceso de preparación de datos con el objetivo de garantizar la calidad, consistencia y utilidad del dataset antes de su utilización en los modelos de deep learning.

3.1. LECTURA Y LIMPIEZA DE DATOS

La primera etapa del proyecto se centró en la lectura masiva de los archivos .txt, aprovechando la biblioteca glob para recorrer de forma recursiva toda la estructura de carpetas. A diferencia de las primeras versiones del pipeline, cada archivo se procesó por separado para conservar su procedencia y evitar mezclar señales de sesiones distintas. Durante este proceso, para cada archivo se validó que cumpliera con los criterios mínimos de calidad necesarios para trabajar correctamente con señales EMG. En particular, se verificó que:

- El archivo contará exactamente con diez columnas (tiempo, los ocho canales EMG y la etiqueta)
- Todos los valores fueran numéricos y no hubiera caracteres inválidos
- La etiqueta fuera distinta de cero, descartando así segmentos vacíos o sin gesto
- Y que no existieran filas incompletas, corruptas o con un formato inconsistente.

Cualquier fila que incumpliera estas condiciones se eliminó. Esta depuración inicial fue fundamental para asegurar que todos los archivos compartieran una estructura bastante igual y, sobre todo, para evitar que errores de formato afectarían las etapas posteriores de normalización y segmentación temporal.

Además, a cada registro se le agregó una columna *source_file* para conservar el archivo de origen. Esto permitió generar ventanas por archivo y posteriormente dividir el dataset por archivo, evitando que ventanas de una misma sesión quedaran repartidas entre entrenamiento, validación y prueba.

3.2. NORMALIZACIÓN POR CANAL

Las señales EMG suelen variar bastante entre sujetos, sesiones y hasta entre los mismos canales. Para reducir esta variabilidad y facilitar el trabajo de los modelos, se aplicó una estandarización por canal utilizando StandardScaler. Con ello, cada canal EMG quedó ajustado a una media de 0 y una desviación estándar de 1.

$$x_{norm} = \frac{x - \mu}{\sigma}$$

Figura 0. Fórmula de normalización (o estandarización)

La normalización se aplicó después de dividir el dataset en entrenamiento, validación y prueba. Para evitar data leakage, el StandardScaler se ajustó únicamente con las ventanas del conjunto de entrenamiento. Después, ese mismo scaler se aplicó a entrenamiento, validación y prueba. De esta manera, los conjuntos de validación y prueba se mantuvieron como datos desconocidos para el modelo.

3.3. SEGMENTACION MEDIANTE VENTANAS DESLIZANTES

Después de limpiar cada archivo, se procedió a la segmentación temporal por archivo aplicando una estrategia de sliding windows. Esta decisión evitó que una ventana cruzara el final de una sesión y el inicio de otra, y también permitió rastrear de qué archivo provenía cada ventana. Se establecieron ventanas de 200 muestras con un desplazamiento de 100 muestras entre una ventana y la siguiente.

Para asegurar que cada ventana representara un único gesto bien definido, solo se conservaron aquellas en las que todas las etiquetas internas coincidían. Este criterio permitió descartar transiciones entre gestos y garantizó que cada fragmento fuera una unidad temporal coherente para su uso en clasificación supervisada.

Cada ventana generada corresponde a una matriz de $200 \text{ time steps} \times 8 \text{ canales EMG}$, lo que transformó las señales continuas en instancias independientes, adecuadas tanto para modelos recurrentes como para arquitecturas híbridas convolucional recurrentes.

3.4. DIVISIÓN DEL DATASET POR ARCHIVO

Una vez generadas las ventanas, la división se realizó por archivo y no por ventana. Esto significa que todas las ventanas provenientes de un mismo archivo quedaron en el mismo subconjunto. Esta corrección fue necesaria porque las ventanas consecutivas comparten información debido al solapamiento de 50%, por lo que dividir aleatoriamente por ventana podía provocar data leakage.

Se mantuvo una proporción aproximada de 80% para entrenamiento, 10% para validación y 10% para prueba. Además, se buscó un *random_state* que garantizará que todas las clases estuvieran presentes en los tres subconjuntos.

Además, como se eliminó la etiqueta 0, las etiquetas originales quedaron del 1 al 7. Sin embargo, para entrenar con CrossEntropyLoss, estas etiquetas se codificaron internamente de 0 a 6. Para evitar

confusiones, se guardaron los diccionarios labelToIndex e indexToLabel, permitiendo recuperar las etiquetas originales al momento de evaluar o usar la interfaz.

El data augmentation se aplicó únicamente sobre el conjunto de entrenamiento. Esto evita que copias o variaciones de una misma ventana aparezcan en validación o prueba. A diferencia de la primera versión, donde solo se duplicaban ventanas, en la versión corregida se aplicaron transformaciones suaves como ruido gaussiano, escalamiento por canal y pequeños desplazamientos temporales.

3.5. CONSTRUCCIÓN DE DATA LOADERS PARA ENTRENAMIENTO

Finalmente, cada subconjunto fue encapsulado en una clase personalizada llamada EMGDataset, construida a partir de la clase Dataset de PyTorch. Esta clase se encargó de convertir cada ventana en tensores, gestionar el acceso por índices y permitir una integración directa con los DataLoader durante el entrenamiento.

Cada DataLoader generó lotes de 64 ventanas seleccionadas aleatoriamente en cada época, lo que hizo posible entrenar mediante mini-batches. De esta manera, el flujo completo de datos quedó optimizado para entrenamientos prolongados y arquitecturas de mayor complejidad.

3.6. HIPERPARAMETROS GENERALES DE LOS MODELOS

A fin de garantizar una comparación objetiva entre las diferentes arquitecturas evaluadas, los cuatro modelos desarrollados (LSTM, CNN+LSTM, BiLSTM y CNN+BiLSTM+Attention) compartieron un conjunto de hiperparámetros base que se mantuvieron constantes durante todo el proceso experimental. Estos hiperparámetros definen las condiciones de entrenamiento y permiten aislar el efecto real de las modificaciones arquitectónicas introducidas en cada versión del modelo.

3.6.1. HIPERPARÁMETROS COMPARTIDOS EN LOS CUATRO MODELOS

- Número de épocas: 200
- Tamaño de batch: 64
- Optimizador: Adam
- Learning rate: 0.001
- Función de pérdida: CrossEntropyLoss
- Criterio de selección del mejor modelo: mayor validation accuracy alcanzada durante el entrenamiento
- Dispositivo de entrenamiento: GPU (colab)

- Segmentación de ventanas de 200 muestras con desplazamiento de 100
- Split por archivo
- Normalización: StandardScaler ajustado solo con train
- Data augmentation: En train
- Pesos por clase: Calculados solo con train

El uso del optimizador Adam con learning rate fijo proporcionó una convergencia estable y consistente entre modelos, mientras que los 200 epochs permitieron observar tendencias claras sin alterar el presupuesto computacional disponible. El batch size de 64 se eligió como un punto intermedio que equilibraba eficiencia computacional y estabilidad del gradiente, permitiendo entrenar adecuadamente incluso en GPUs limitadas.

Se mantuvieron estos hiperparámetros constantes para que la comparación final reflejara únicamente las mejoras derivadas del diseño del modelo, sin ningún sesgo por cambios en las condiciones de entrenamiento.

Cabe mencionar que durante el desarrollo del proyecto se corrigió el pipeline de preparación de datos para evitar data leakage. Por ello, la interpretación final da mayor peso a la versión corregida del flujo experimental, especialmente en el Modelo 4, donde el split por archivo, la normalización solo con train y el data augmentation únicamente en entrenamiento permiten una evaluación más confiable. En el caso de los modelos anteriores, sus resultados se interpretan como parte de la evolución experimental del proyecto, mientras que el Modelo 4 representa la versión más actualizada tanto en arquitectura como en preparación de datos..

4. MODELO 1: LSTM UNIDIRECCIONAL PARA CLASIFICACIÓN DE GESTOS EMG

Este primer modelo tiene una arquitectura basada en una red LSTM unidireccional, seleccionada como aproximación inicial debido a su capacidad para procesar series temporales multivariadas y modelar dependencias dinámicas presentes en señales EMG. El objetivo de este primer prototipo fue establecer una línea base sobre la cual desarrollar mejoras en el futuro.

Como ya mencionamos se basa en una arquitectura secuencial sencilla, diseñada como línea base para la clasificación de gestos EMG. El núcleo del modelo es una capa LSTM unidireccional, configurada con un input_size de 8 características correspondientes a los canales del brazalete MYO, un hidden_size de 64 unidades recurrentes y una única capa (num_layers = 1). Esta configuración permite capturar patrones temporales básicos presentes en la actividad muscular, mientras que un dropout del 30% ayuda a mitigar el sobreajuste. A la

salida del LSTM se incorpora una capa totalmente conectada de 64 neuronas con activación ReLU, encargada de hacer la transformación de la representación secuencial en un espacio latente más compacto y no lineal. Posteriormente, se aplica nuevamente un dropout del 30% para reforzar la regularización y mejorar la capacidad de generalización. Finalmente, el modelo concluye con una capa densa de 7 neuronas, cada una asociada a una de las clases de gestos. Esta arquitectura aprovecha la capacidad de la LSTM para capturar la dinámica muscular a lo largo de las ventanas temporales de 200 muestras, extrayendo características relevantes de cada gesto.

4.1. ENTRENAMIENTO Y CURVAS DE APRENDIZAJE




Figura 1. Curvas de entrenamiento del modelo 1 (LSTM)

Durante el entrenamiento se observó un descenso progresivo y estable de la función de pérdida, sin oscilaciones fuertes ni nada de comportamientos irregulares o raros. Este patrón, ilustrado en la Figura 1, sugiere que la red logró aprender representaciones consistentes a partir de las señales EMG, ajustando gradualmente sus parámetros sin evidencias de inestabilidad numérica o sobreajuste temprano. Paralelamente, la curva de exactitud en validación muestra que el modelo mantiene un incremento constante a lo largo de las épocas, estabilizándose alrededor del 71%.

El mejor desempeño alcanzado por el modelo corresponde a una accuracy de validación del 71.81%, mientras que la evaluación final en el conjunto de prueba arrojó una accuracy del 69.94%. Eso nos dice que el modelo es capaz de capturar ciertos patrones musculares relevantes, aunque podría mejorar.

4.2. EVALUACIÓN CUANTITATIVA

4.2.1. MÉTRICAS GLOBALES (TEST SET)

**Entrenamiento finalizado.
Mejor accuracy de validación: 71.81%**

Accuracy en test set: 69.94%
MAE (Test): 1.0109
Bias (Test): -0.0570
Varianza (Test): 3.9233

Figura 2. Métricas globales del Modelo 1 (LSTM)

La evaluación cuantitativa del Modelo 1 en el conjunto de prueba muestra un desempeño que podría considerarse moderado como podemos ver en la figura 2. Estos resultados (Figura 2), se aprecia que el error absoluto medio indica que, en promedio, el modelo se equivoca aproximadamente por una clase en sus predicciones.

El valor del sesgo, cercano a cero, nos dice que las predicciones no presentan una tendencia hacia la sobreestimación o subestimación de clases. Sin embargo, la varianza nos dice que hay una dispersión moderada de las predicciones, lo cual tiene sentido con la naturaleza ruidosa y muy variable de las señales EMG. En conjunto, estas métricas sugieren un comportamiento estable y bueno, aunque limitado en cuanto a capacidad de diferenciar entre gestos que son parecidos entre sí.

Reporte de clasificación:				
	precision	recall	f1-score	support
0	0.7622	0.8261	0.7929	2887
1	0.0000	0.0000	0.0000	249
2	0.5781	0.6141	0.5956	241
3	0.5391	0.5020	0.5199	247
4	0.5072	0.5645	0.5344	248
5	0.5531	0.5000	0.5252	250
6	0.5504	0.5657	0.5580	251
7	0.3846	0.3333	0.3571	15
accuracy			0.6994	4388
macro avg	0.4844	0.4882	0.4854	4388
weighted avg	0.6566	0.6994	0.6769	4388

Figura 3. Reporte de clasificación del Modelo 1 (LSTM)

El desempeño por clase, presentado en la Figura 3, muestra un comportamiento bastante desigual. La clase interna 0, correspondiente a la etiqueta original 1, domina parte de las predicciones del modelo y, como consecuencia, alcanza las métricas más altas ($F1 = 0.7929$), reflejando que el modelo logra identificar patrones de la clase interna 0. Sin embargo, las otras clases presentan problemas en su clasificación, por ejemplo:

- La clase 1 obtiene métricas de 0, indicando que el modelo no identificó bien ni un solo ejemplo de esta categoría. Esto puede deberse a que se parecen mucho los patrones electromiográficos con otras clases de gestos.

- La clase 7, con apenas 15 muestras en el test set, también muestra un rendimiento bastante bajo ($F1 = 0.3571$), se ve muy claro el desbalance que hay en la capacidad del modelo para prender gestos que están poco representados.

Las clases intermedias (como 2 a 6) muestran métricas moderadas y relativamente normales, con F1-scores entre 0.51 y 0.59, lo que sugiere que el modelo captura parcialmente sus características, pero aún tiene dificultades para separarlas realmente.

4.2.2. MATRIZ DE CONFUSIÓN




Figura 4. Matriz de confusión del test set del modelo 1 (LSTM)

La matriz de confusión, mostrada en la Figura 4, confirma varios de los patrones detectados previamente. En primer lugar, el modelo presenta una fuerte tendencia a sobredetectar la clase 0. Esto nos dice que la señal de la clase 0 predomina la representación aprendida por el modelo, posiblemente porque es de los gestos más representados en el dataset, es decir, hay más datos.

Además, la matriz nos muestra que hay veces que el modelo confunde gestos entre ellos, por ejemplo cuando habla de flexión y extensión (clase 3 y 4) o cuando habla de desviación radial y desviación cubital (clase 5 y 6). Estas confusiones son esperables, ya que estos pares de gestos se parecen mucho hablando más en patrones electromiográficos, especialmente en la activación de grupos musculares vecinos.

Finalmente, la matriz confirma que el modelo no reconoce nunca la clase 1, ya que muchos de sus ejemplos fueron clasificados como la clase interna 0, correspondiente a la etiqueta original 1. Esto nos recalca la incapacidad del LSTM unidireccional para extraer características distintivas de gestos que son menos

representados, incluso con regularización y entrenamiento extendido.

5. CONCLUSIÓN DE LA PRIMERA VERSIÓN DEL MODELO

El análisis del Modelo 1 permitió darnos cuenta que hubo mucho desbalance significativo entre clases, esto afectó directamente la capacidad del modelo para aprender representaciones adecuadas de los gestos minoritarios, favoreciendo a la tendencia de predecir la clase que está más representada y mejor identificada, la cual es la clase 0. Esto empeora porque hubo mucha similitud en los demás gestos, cuyos patrones electromiográficos presentan diferencias sutiles que resultan difíciles de distinguir mediante una arquitectura LSTM unidireccional simple.

Asimismo, el esquema de segmentación que esta basado en ventanas monoclasa, si reduce el ruido temporal, pero realmente no resuelve nada de la variabilidad baja de algunos gestos, lo que nos baja mucho la diversidad de los patrones que puede aprender el modelo. Esto nos muestra que una única capa LSTM de 64 unidades resulta insuficiente para capturar dependencias espaciotemporales complejas.

A pesar de estas limitaciones, el Modelo 1 alcanzó un desempeño aceptable y permitió confirmar la viabilidad del enfoque secuencial. Sin embargo, debido a que este modelo no puede reconocer algunas clases y se confunde entre gestos fisiológicamente iguales nos dice que es necesario ampliar la complejidad de la arquitectura. Esto nos lleva a intentar un modelo 2 mejorado que use capas convolucionales y tenga una mayor profundidad temporal.

6. MODELO 2: ARQUITECTURA HÍBRIDA CNN + LSTM PARA CLASIFICACIÓN DE GESTOS EMG (1ERA MEJORA)

Tras analizar las limitaciones del Modelo 1, particularmente su dificultad para distinguir gestos con patrones musculares similares y su incapacidad para modelar relaciones espaciales entre los canales EMG, se propuso una segunda aproximación basada en una arquitectura híbrida Convolutiva + LSTM (CNN+LSTM). Este tipo de modelo es ampliamente utilizado en señales fisiológicas multicanal debido a su habilidad para extraer características espacialmente relevantes antes de procesar la secuencia temporal completa [2].

El objetivo principal es extraer características espaciales locales antes del modelado temporal. Por esto usamos la convolución ya que nos permite identificar

correlaciones entre canales adyacentes, filtrar ruido y generar representaciones más ricas para la etapa recurrente. También dejamos la normalización por lotes, el max pooling y el dropout para intentar contribuir a estabilizar el aprendizaje y mejorar la generalización. Al proveer una representación refinada de la señal, la CNN facilita que la LSTM capture patrones temporales complejos y, en consecuencia, aumenta significativamente la capacidad discriminativa del modelo frente a gestos altamente similares en el espacio fisiológico.

6.1. MEJORAS Y CAMBIOS

El Modelo 2 adopta una arquitectura híbrida compuesta por tres bloques principales: un módulo convolutivo, un módulo recurrente y una cabeza densa de clasificación final. Entonces vamos paso por paso a explicar cada una de ellas:

6.1.1. BLOQUE CONVOLUCIONAL (CNN 1D)

Este bloque recibe la señal con forma y aplica dos etapas de convolución secuencial. La primera capa Conv1D transforma los 8 canales originales en 32 mapas de características utilizando un kernel de tamaño 3, seguida de "Batch Normalization", activación ReLU y un dropout del 20% para reducir sobreajuste. La segunda convolución es de 64 filtros, también seguida de ReLU y un MaxPool1D con factor 2, que reduce la resolución temporal y enfatiza en los patrones que nos importan que son los más relevantes para intentar hacer una mejora respecto al modelo 1. Este bloque permite aprender correlaciones locales entre canales, algo que el Modelo 1 no podía capturar.

6.1.2. BLOQUE RECURRENTE (LSTM)

La salida convolutiva se "reordena" para dársele a una LSTM configurada con un input_size de 64 y un hidden_size de 64. Esta red recurrente identifica dependencias temporales a lo largo de las 200 muestras de cada ventana, donde se aprovecha la representación que se obtuvo de la CNN.

6.1.3. CABEZA Densa DE CLASIFICACIÓN

Finalmente, las características aprendidas se pasan a un perceptrón de dos capas: una capa lineal de 64 unidades con activación ReLU y dropout del 30%, seguida de una capa lineal final de 7 neuronas correspondientes a las clases de gestos de nuestro dataset. Este bloque produce las probabilidades de clasificación a partir del embedding temporal generado por la LSTM.

6.2. ENTRENAMIENTO Y CURVAS DE APRENDIZAJE




Figura 5. Curvas de entrenamiento del modelo 2 (CNN + LSTM)

El proceso de entrenamiento del Modelo 2 evidenció un comportamiento considerablemente más estable que el observado en el Modelo 1. Tal como se muestra en la Figura 5, la función de pérdida presentó un descenso progresivo, lo que indica que la combinación CNN-LSTM facilitó un aprendizaje más controlado y robusto.

De manera paralela, la curva de exactitud en validación alcanzó valores parecidos a los mejores registrados en el Modelo 1; sin embargo, lo hizo manteniendo una evolución más uniforme y con menos variabilidad entre épocas.

6.3. EVALUACIÓN CUANTITATIVA

6.3.1. MÉTRICAS GLOBALES (TEST SET)

Entrenamiento finalizado.
Mejor accuracy de validación: 74.41%

Accuracy en test set: 74.38%
MAE (Test): 0.8282
Bias (Test): -0.1222
Varianza (Test): 3.7161

Figura 6. Métricas globales del Modelo 2 (CNN + LSTM)

El desempeño cuantitativo del Modelo 2 mostró mejoras con respecto al Modelo 1. Como se observa en la Figura 6, el modelo alcanzó una accuracy de validación de 71.81% y en el conjunto de prueba una de 74.38%, lo que representa un incremento de 4.44 puntos porcentuales. Además, métricas como el MAE, bias y varianza son un poco mejores ya que no tienen error promedio y tienen una dispersión menor entre cada clase.

Reporte de clasificación:				
	precision	recall	f1-score	support
0	0.7889	0.8608	0.8233	2887
1	0.3662	0.1044	0.1625	249
2	0.7235	0.6515	0.6856	241
3	0.6135	0.6235	0.6185	247
4	0.6233	0.5403	0.5788	248
5	0.6360	0.6360	0.6360	250
6	0.6544	0.5657	0.6068	251
7	0.4118	0.4667	0.4375	15
accuracy			0.7438	4388
macro avg	0.6022	0.5561	0.5686	4388
weighted avg	0.7244	0.7438	0.7285	4388

Figura 7. Reporte de clasificación del Modelo 2 (CNN + LSTM)

Además, los resultados del reporte de clasificación, presentados en la Figura 7, muestran una mejora significativa en el rendimiento por clase respecto al Modelo 1. El macro F1-score aumentó de 0.4854 a 0.5686, mientras que el weighted F1-score pasó de 0.6769 a 0.7285, lo que demuestra un equilibrio entre clases, algo que estábamos buscando.

Aunque la clase 0 continúa siendo la mejor precisión de todas las clases. El Modelo 2 logra una mejora en varias clases clave, incluyendo flexión, extensión, desviaciones radial y cubital, y palma extendida. La clase 1 sigue siendo problemática debido a su baja representatividad, aunque, a diferencia del Modelo 1, el Modelo 2 comienza a mostrar predicciones correctas.

4.3.2. MATRIZ DE CONFUSIÓN




Figura 8. Matriz de confusión del test set del modelo 2 (CNN + LSTM)

La Figura 8 evidencia una reducción en los patrones de confusión que afectaban al Modelo 1. El Modelo 2 disminuye la tendencia a clasificar mal algunos gestos como la clase 0, lo que sugiere una mayor discriminación.

muscular y un aprendizaje más equilibrado entre categorías. Asimismo, se observa una mejor identificación en las clases 2 a 6.

A pesar de estas mejoras, la clase 7 sigue siendo difícil de aprender debido a sus pocas muestras (15 muestras), lo que limita la capacidad del modelo para aprender sus patrones característicos. Aun así, el modelo muestra una separación más clara entre gestos similares fisiológicamente hablando.

7. CONCLUSIÓN DE LA SEGUNDA VERSIÓN DEL MODELO

El análisis del Modelo 2 confirma que cuando integramos un bloque convolucional antes del módulo recurrente mejoró un poco respecto al enfoque puramente secuencial del Modelo 1. La combinación de la CNN y una LSTM nos ayudó a tener una mejor capacidad discriminativa, un aumento significativo en la accuracy de prueba y una reducción tanto del MAE como de la varianza.

No obstante, algunas limitaciones persisten. La clase 1 continúa siendo difícil de reconocer, lo que sugiere que aún tenemos un problema presente de desbalance. Del mismo modo, los gestos que tenemos menos muestras como la clase 7 mantienen un rendimiento bajo. Esto nos dice que aunque la arquitectura CNN+LSTM mejora la representación espacio temporal, todavía podemos mejorar la robustez del modelo especialmente las clases con baja frecuencia.

El Modelo 2 representa un avance significativo frente al primer enfoque pero para mejorar las licitaciones mencionadas previamente, intentamos mejorar el modelo incorporando una arquitectura BiLSTM y estrategias explícitas de data augmentation, con el objetivo de mejorar la representación temporal bidireccional y abordar de manera más directa la falta de ejemplos en clases con pocas muestras.

8. MODELO 3: ARQUITECTURA BiLSTM CON DATA AUGMENTATION Y REBALANCEO DE CLASES (2DA MEJORA)

Tras evaluar el desempeño del Modelo 2, se identificaron dos limitaciones que impedían mejorar la clasificación de ciertos gestos:

- Bajo rendimiento en clases minoritarias, particularmente en las clases 1 y 7, que en el dataset original tenían únicamente 249 y 15 muestras, respectivamente. Este desbalance provocaba que los modelos pasados tendieran a

clasificar estos gestos como clase 0, afectando incluso el rendimiento general del modelo.

- Dificultad para capturar patrones temporales complejos, ya que una arquitectura unidireccional sigue una sola trayectoria temporal y no logra modelar transiciones musculares más discretas que ocurren antes y después del gesto principal.

Además, durante el análisis comparativo entre el Modelo 1 y el Modelo 2 se observó que el desbalance extremo del dataset estaba afectando bastante la capacidad de generalización, ya que incluso al mejorar la arquitectura (CNN+LSTM), las clases 1 y 7 seguían siendo mal clasificadas o ignoradas por completo. Esto llevó a la conclusión de que era necesario intervenir explícitamente en la estructura de los datos con técnicas de data augmentation.

Por ello, el Modelo 3 incorpora tres mejoras fundamentales:

- BiLSTM bidireccional
- Data augmentation dirigido
- Class weights

Este conjunto de cosas nos permitió construir una arquitectura más robusta y equilibrada, incrementando así la capacidad discriminativa del modelo y reduciendo la confusión entre señales musculares parecidas.

8.1. MEJORAS Y CAMBIOS

8.1.1. USO DE UNA BiLSTM

Las señales EMG presentan dinámicas temporales complejas donde la anticipación y el decaimiento de la activación muscular contienen información relevante. Mientras que una LSTM unidireccional únicamente considera el pasado, una BiLSTM incorpora simultáneamente el contexto temporal precedente y subsecuente. Esto permite:

- Detectar transiciones musculares con mayor claridad
- Capturar movimientos suaves que requieren información bidireccional
- Reducir confusiones entre gestos fisiológicamente parecidos porque esas diferencias se manifiestan de manera temporal.

8.1.2. DATA AUGMENTATION EN CLASES 1 Y 7

Uno de los principales problemas del modelo 1 y el modelo 2 es que el dataset original presentaba un desbalance ya que la clase 1 contaba con 249 muestras, mientras que la clase 7 tenía únicamente 15 muestras.

Esto causaba que los modelos detectan mejor las clases que tenían más muestras o que eran mayoritarias como la clase 0.

Pensando en esto, se aplicó oversampling dirigido, duplicando las ventanas pertenecientes a las clases más pequeñas, incrementando la exposición del modelo a los patrones reales de estas clases con menores muestras.

8.1.3. USO DE CLASS WEIGHTS

Debido a que el desbalance que tenemos en nuestro dataset es muy marcado. Se incorporaron pesos por clase, asignando valores mayores a las clases 1 y 7 [1.0, 1.5, 1.0, 1.0, 1.0, 1.0, 2.0].

Esto lo que hace es que penaliza más los errores cometidos en clases con menos muestras y refuerza su aprendizaje, complementando así el data augmentation y estabilizando la contribución de cada clase al proceso de optimización.

8.1.4. ARQUITECTURA NUEVA

La arquitectura del Modelo 3 introduce una estructura bastante más robusta que las versiones pasadas. El núcleo del modelo es un bloque BiLSTM de dos capas, configurado con un tamaño de entrada de ocho canales EMG, un espacio oculto de 64 unidades por dirección y una tasa de dropout del 30%. La bidireccionalidad permite que el modelo procese al mismo tiempo la información temporal hacia adelante y hacia atrás. Esto es importante ya que en problemas como estos necesitamos tener cotexto anterior y posterior ya que nos da elementos esenciales para la correcta discriminación entre gestos.

Sobre la salida del bloque recurrente se implementa una cabeza densa de clasificación para transformar esta representación bidireccional en algo más compacto. Este componente consta de una capa lineal de 64 unidades con activación ReLU, acompañada de un dropout del 30% para reducir el sobreajuste. Finalmente, una segunda capa lineal proyecta este espacio latente hacia las siete clases activas del problema, generando las probabilidades correspondientes a cada gesto. Esta nueva arquitectura nos permite incrementar la capacidad del modelo para diferenciar gestos fisiológicamente parecidos y para aprender patrones que nos son tan visibles o notables en las señales EMG multicanal.

8.2. ENTRENAMIENTO Y CURVAS DE APRENDIZAJE




Figura 9. Curvas de entrenamiento del modelo 3 (BiLSTM + Data augmentation + rebalanceo de clases)

Las curvas de aprendizaje del Modelo 3, presentadas en la Figura 9, evidencian un proceso de entrenamiento más estable que el pasado y constante. La función de pérdida muestra un descenso suave y continuo sin indicios de sobreajuste, lo que confirma que la arquitectura bidireccional, junto con la regularización aplicada, permitió un aprendizaje bastante controlado a lo largo de las épocas. La exactitud en validación incrementa de manera sostenida hasta aproximarse al 80%. Este comportamiento es más robusto que el observado en los modelos pasados.

Un factor clave detrás de esta mejora fue la estrategia de data augmentation dirigida, que consistió en duplicar las ventanas de las clases 1 y 7. Esta intervención aumentó su presencia durante el entrenamiento sin alterar nada de la estructura fisiológica de las señales. Esto lo que causó es que el modelo pudo recibir más cantidad de muestras y aprender mejor los patrones de esas clases en particular. La evolución positiva tanto de la pérdida como de la exactitud de validación demuestra que el oversampling, junto con el uso de class weights, nos ayudo bastante a mejorar la estabilidad del entrenamiento y la discriminación de clases minoritarias.

Por último podemos observar que debido a la curva que tenemos de pérdida, podríamos decir que si le ponemos más épocas a nuestro modelo podría mejorar aún más ya que el accuracy y la pérdida son bastante constantes y progresivas. Pero por limitaciones en la GPU de los dispositivos que usamos para entrenar al modelo solo pusimos las 200 épocas.

8.3. EVALUACIÓN CUANTITATIVA

8.3.1. MÉTRICAS GLOBALES (TEST SET)

Entrenamiento finalizado.
Mejor accuracy de validación: 80.05%

Accuracy en test set: 79.62%
MAE (Test): 0.6412
Bias (Test): 0.0114
Varianza (Test): 3.6433

Figura 10. Métricas globales del Modelo 3 (BiLSTM + Data augmentation + rebalanceo de clases)

Los resultados cuantitativos del Modelo 3, mostrados en la Figura 10, reflejan el mayor desempeño alcanzado en todo el proyecto. El modelo obtuvo una accuracy de validación del 80.05% y una accuracy en el conjunto de prueba del 79.62%, superando a las arquitecturas anteriores. Además, los valores de MAE, bias y varianza indican un modelo relativamente equilibrado y estable. El sesgo es prácticamente, esto demuestra que el modelo no favorece de ninguna manera a ninguna clase, mientras que la disminución del MAE no dice que las predicciones son más cercanas a las etiquetas reales. En resumen, estos indicadores nos confirman que al usar una BiLSTM bidireccional, junto con técnicas de rebalanceo de datos, si nos sirvió para poder obtener un modelo más preciso y con una mejor generalización.

Reporte de clasificación:				
	precision	recall	f1-score	support
0	0.8577	0.8265	0.8418	2887
1	0.7145	0.8494	0.7761	498
2	0.7208	0.7925	0.7549	241
3	0.6761	0.6761	0.6761	247
4	0.7108	0.7108	0.7108	249
5	0.6553	0.6948	0.6745	249
6	0.7260	0.6335	0.6766	251
7	0.8235	0.9333	0.8750	30
accuracy			0.7962	4652
macro avg	0.7356	0.7646	0.7482	4652
weighted avg	0.7996	0.7962	0.7968	4652

Figura 11. Reporte de clasificación del Modelo 3 (BiLSTM + Data augmentation + rebalanceo de clases)

En cuanto al reporte de clasificación mostrado en la Figura 11 nos muestra que la mejora que realizamos fue muy buena en términos generales para todas las clases, justamente eliminando el problema de desbalanceo que teníamos presente en las versiones pasadas del modelo. El Modelo 3 alcanzó valores de F1-score superiores a 0.67 en todas las categorías, lo que representa un equilibrio entre clases bastante bueno para un problema de señales EMG.

Podemos destacar tres cosas:

- La clase 1, la cual era la más problemática en los modelos anteriores, alcanzó un recall de 0.8494, lo cual se puede atribuir al oversampling

dirigido y al uso de class weights que se aplicaron para este modelo.

- La clase 7, en el Modelo 1 tenía un F1 de 0.35, pero con esta nueva arquitectura obtuvo un F1-score de 0.875. Lo que sería la mayor mejora registrada en todo el proyecto.
- Todas las clases presentan métricas altas, con mejoras en precisión, recall y F1-score.

8.3.2. MATRIZ DE CONFUSIÓN




Figura 12. Matriz de confusión del test set del modelo 3 (BiLSTM + Data augmentation + rebalanceo de clases)

La matriz de confusión, presentada en la Figura 12, sustenta lo que acabamos de observar y analizar en la sección pasada porque nos muestra que el Modelo 3 tiene una separación buena y efectiva entre las clases 1, 2, 3, 4, 5 y 7, con una cantidad mínima de falsos positivos. Destacando la clase 7, donde el modelo realizó 28 aciertos de 30 muestras, demostrando que el rebalanceo del dataset y la arquitectura bidireccional permitieron capturar mejor los patrones distintivos que antes no se podían detectar.

La clase 0, aunque sigue siendo aún la más representada, ya no absorbe predicciones incorrectas con la misma frecuencia que en los Modelos 1 y 2. Sin embargo la clase 6 aun tiene cierta confusión entre las clases 0 y 3, ya que tienen bastante similitud fisiológica en la activación muscular.

Todo esto mencionado anteriormente nos demuestra que la nueva arquitectura BiLSTM ayuda mucho en la captura de las dinámicas temporales bidireccionales. Además, junto con las estrategias de rebalanceo aplicadas nos ayudaron a quitar las limitaciones que tenía nuestro dataset y permitir mejorar el aprendizaje de todas las categorías del problema.

9. CONCLUSIÓN DE LA TERCERA VERSIÓN DEL MODELO

El Modelo 3 fue la arquitectura con el rendimiento más alto y el comportamiento más estable entre todas las alternativas evaluadas. Su diseño abordó de manera directa dos limitaciones críticas observadas en los modelos pasados:

- La incapacidad para aprender clases minoritarias (como las clases 1 y 7, con 249 y apenas 15 muestras respectivamente)
- La insuficiencia de las arquitecturas unidireccionales para capturar patrones temporales complejos característicos de las señales EMG.

Entonces, la incorporación de una BiLSTM bidireccional de dos capas, combinada con regularización mediante dropout, nos dio la posibilidad de modelar dependencias temporales tanto hacia adelante como hacia atrás, mejorando la detección de patrones con transiciones musculares sutiles o discretas que eran las que más problema tenían en las versiones anteriores. Además, la estrategia de oversampling dirigido tuvo un impacto fuerte. Esta fue implementada tras observar que los modelos 1 y 2 se inclinaban más hacia clases mayoritarias debido a que teníamos un desbalance extremo en el dataset. La duplicación de las muestras de las clases 1 y 7, complementada con un esquema de class weights, corrigió este desequilibrio y permitió que el modelo aprendiera mejores representaciones de estas categorías difíciles de distinguir.

En resumen, el Modelo 3 alcanzó mejoras significativas, resolviendo completamente el problema crítico de la clase 1 y transformando la clase 7, que antes era poco reconocible, en una de las más precisas del modelo. Las curvas de aprendizaje mostraron un entrenamiento estable, mientras que la métrica de prueba alcanzó un 79.62% de accuracy, el valor más alto de todo el proyecto. Este desempeño se reflejó y mantuvo también en indicadores como MAE, bias y varianza.

10. MODELO 4: ARQUITECTURA CNN + BiLSTM + ATTENTION PARA CLASIFICACIÓN DE GESTOS EMG (3ERA MEJORA)

Después de evaluar el desempeño del Modelo 3, se observó que la incorporación de una BiLSTM, data augmentation y rebalanceo de clases permitió mejorar el desempeño del modelo. Sin embargo, la arquitectura del Modelo 3 no incluía un bloque convolucional ni mecanismos de atención. Por esta razón, se propuso una cuarta versión basada en una arquitectura CNN + BiLSTM + Attention.

Esta propuesta se sustenta en estudios del estado del arte recientes que han demostrado que la combinación de redes convolucionales, modelos recurrentes y mecanismos de atención puede mejorar el reconocimiento de gestos basado en señales sEMG. Por ejemplo, Wang et al. proponen un modelo Attention-based LSTM-CNN para reconocimiento de gestos sEMG, donde la atención(Attention) permite enfocarse en la información más relevante de la señal [6]. De manera similar, Guo y Li muestran que una BiLSTM con mecanismo de atención puede mejorar la estabilidad y precisión de gestos sEMG [9]. Además, otros trabajos recientes han explorado arquitecturas jerárquicas, multistream y de fusión espacio-temporal para mejorar la extracción de características en señales electromiográficas [7], [8], [10].

Por ello, el Modelo 4 incorpora tres mejoras principales:

1. CNN 1D para extracción de características espaciales y locales.
2. BiLSTM bidireccional para modelar dependencias temporales hacia adelante y hacia atrás.
3. Mecanismo de atención temporal para asignar mayor peso a los instantes importantes de la señal.

10.1. MEJORAS Y CAMBIOS

10.1.1. USO DE UN BLOQUE CNN 1D

Esta primera mejora del Modelo 4 consiste en utilizar un bloque convolucional 1D antes de la BiLSTM, algo que ya hacíamos en las versiones pasadas pero con LSTM. Esta decisión se tomó porque el Modelo 2 ya había demostrado que las convoluciones ayudan a extraer características entre los canales EMG. En este caso, la CNN recibe la señal en forma de canales por tiempo y aplica dos capas convolucionales.

La primera capa Conv1D transforma los 8 canales originales en 32 mapas de características, utilizando un kernel de tamaño 3, Batch Normalization, activación ReLU y dropout del 20%. Posteriormente, una segunda capa Conv1D transforma estas características en 64 mapas, también con Batch Normalization, ReLU, MaxPooling y dropout.

Esta etapa es importante porque las señales EMG no solo tienen información temporal, sino también relaciones entre canales. Esta idea coincide con trabajos como FFCSLT, donde se utilizan bloques convolucionales y mecanismos de identificación de

canales para la extracción de características espaciales en señales sEMG [8].

10.1.2. USO DE UNA BiLSTM BIDIRECCIONAL

Después del bloque CNN, la salida es procesada por una BiLSTM de dos capas. Esta BiLSTM recibe 64 características por instante temporal y utiliza 64 unidades ocultas. Al ser bidireccional, procesa la señal hacia adelante y hacia atrás, generando una representación de 128 características por cada instante en el tiempo.

Esta parte se mantuvo ya que fue una de las cosas que más ayudó al modelo 3 a tener buenos resultados, ya que las señales EMG pueden contener información importante tanto antes como después del punto de mayor activación muscular. El uso de BiLSTM en problemas de reconocimiento de gestos EMG también ha sido explorado en trabajos recientes. Le et al. proponen una arquitectura híbrida multistream CNN-Bidirectional LSTM para reconocimiento mioeléctrico, destacando la utilidad de combinar extracción convolucional con modelado temporal bidireccional [10].

10.1.3. MECANISMO DE ATTENTION

La mejora principal del Modelo 4 respecto al Modelo 3 es el mecanismo de atención temporal. En el Modelo 3, la clasificación se realizaba a partir del último estado temporal generado por la BiLSTM, pero eso hacía que solo se enfocara en las características presentes en un solo momento.

La idea del mecanismo de atención es que va a calcular un puntaje para cada instante temporal de la salida que nos da la BiLSTM. Y después, esos puntajes se normalizan mediante softmax para obtener pesos de atención. Y ya con eso, se calcula un vector de contexto como la suma ponderada de todos los estados temporales de la BiLSTM. De esta manera, el modelo aprende qué partes de la ventana deberán tener mayor importancia para clasificar el gesto. Esto se relaciona directamente con los trabajos de Wang et al. y Guo y Li, donde los mecanismos de atención se utilizan para mejorar el reconocimiento de gestos y movimientos continuos a partir de señales sEMG [6], [9].

10.1.4. ARQUITECTURA NUEVA

La arquitectura final del Modelo 4 combina un bloque CNN 1D, una BiLSTM y un mecanismo de atención. Primero, la señal de entrada es de 200 muestras por 8 canales, esta se reordena para que pueda ser pasada por las capas convolucionales. Después, el bloque CNN extrae características locales y reduce la dimensión temporal mediante MaxPooling.

Después, la salida se pasa a una BiLSTM bidireccional de dos capas. Se aplica un mecanismo de atención para calcular un vector de contexto a partir de todos los instantes temporales. Finalmente, este vector se envía a una cabeza densa de clasificación formada por una capa lineal, activación ReLU, dropout del 30% y una capa final con una neurona por clase.

Esta arquitectura combina partes de los modelos pasados, del Modelo 2 toma la CNN, del Modelo 3 conserva la BiLSTM y el rebalanceo. Y como aportación nueva, agrega attention para seleccionar de forma automática los fragmentos temporales más importantes dentro de cada ventana EMG.

10.2. ENTRENAMIENTO Y CURVAS DE APRENDIZAJE




Figura 13. Curvas de entrenamiento del modelo 4 (CNN + BiLSTM + Attention)

Las curvas de aprendizaje (Figura 13) del Modelo 4 muestran un entrenamiento estable y una disminución importante de la pérdida durante las 200 épocas. La función de pérdida final alcanzó un valor de 0.0148, lo cual indica que el modelo logró ajustar los parámetros durante el proceso de entrenamiento. Además, se mantuvieron estrategias ya utilizadas en modelos anteriores, como el uso de class weights para penalizar más los errores en clases con menor representación, dropout para reducir sobreajuste y gradient clipping para estabilizar el entrenamiento de las capas recurrentes.

10.3. EVALUACIÓN CUANTITATIVA

10.3.1. MÉTRICAS GLOBALES (TEST SET)

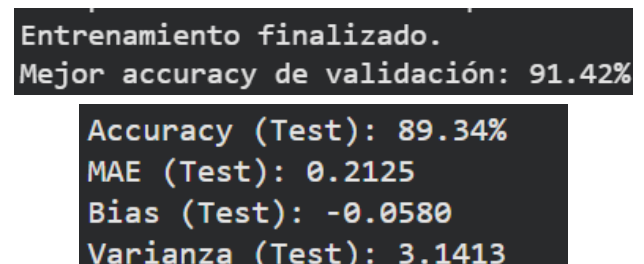


Figura 14. Métricas globales del Modelo 4 (CNN + BiLSTM + Attention)

Como se puede observar en la Figura 14, los resultados del Modelo 4 reflejan el mejor desempeño obtenido en todo el proyecto. El modelo alcanzó una accuracy en el conjunto de prueba de 89.34%, superando a las versiones anteriores. Además, obtuvo un MAE de 0.2125, un bias de -0.0580 y una varianza de 3.1413.

La mejora en accuracy demuestra que la combinación CNN + BiLSTM + Attention permitió mejorar la capacidad de generalización. Asimismo, la reducción del MAE de 0.6412 a 0.2125 indica que las predicciones del Modelo 4 se encuentran mucho más cerca de las etiquetas reales.

El valor del bias se mantiene cercano a cero, lo cual indica que el modelo no presenta una tendencia fuerte hacia la sobreestimación o subestimación de clases. Por otro lado, la varianza también disminuye lo cual nos dice que las predicciones son más estables y menos dispersas.

Reporte de clasificación:				
	precision	recall	f1-score	support
1	0.9056	0.9923	0.9470	261
2	0.8931	0.9628	0.9267	269
3	0.9516	0.8252	0.8839	286
4	0.8534	0.9034	0.8777	290
5	0.9046	0.8434	0.8729	281
6	0.8986	0.8464	0.8717	293
7	0.6410	0.8929	0.7463	28
accuracy			0.8934	1708
macro avg	0.8640	0.8952	0.8752	1708
weighted avg	0.8968	0.8934	0.8931	1708

Figura 15. Reporte de clasificación del Modelo 4 (CNN + BiLSTM + Attention)

En cuanto al reporte de clasificación (Figura 15), el Modelo 4 muestra un desempeño alto en casi todas las clases. Podemos destacar tres aspectos importantes:

1. La clase 1 obtuvo un recall de 0.9923 y un F1-score de 0.9470, lo que representa una mejora muy clara respecto a las versiones iniciales, donde esta clase era una de las más problemáticas.
2. Las clases 2, 3, 4, 5 y 6 presentan F1-scores altos, todos por encima de 0.87.
3. La clase 7, aunque sigue siendo la clase con menor número de muestras en el conjunto de prueba, alcanzó un recall de 0.8929 y un F1-score de 0.7463. Esto muestra que el modelo aún puede reconocer la mayoría de sus ejemplos, aunque haya una poca cantidad de datos disponibles.

En conjunto, estos resultados muestran que la arquitectura CNN + BiLSTM + Attention logró mejorar tanto la precisión global como el equilibrio entre clases.

10.3.2. MATRIZ DE CONFUSIÓN




Figura 16. Matriz de confusión del test set del modelo 4 (CNN + BiLSTM + Attention)

La matriz de confusión del Modelo 4 (Figura 16) confirma los resultados observados en las métricas globales y en el reporte de clasificación. En general, se observa una diagonal principal más marcada, lo que significa que la mayoría de las muestras fueron clasificadas correctamente.

A diferencia de los modelos anteriores, el Modelo 4 reduce la confusión entre clases con patrones musculares similares. La clase 7 sigue siendo la más difícil de clasificar debido a que hay poco datos de ella, pero el modelo logra reconocer una parte de sus muestras. Esto indica que el rebalanceo y el mecanismo de atención ayudaron. En general, la matriz de confusión sustenta que el Modelo 4 tiene una mejor capacidad discriminativa de clasificación que versiones pasadas.

11. CONCLUSIÓN DE LA CUARTA VERSIÓN DEL MODELO

El Modelo 4 fue la arquitectura con el mejor rendimiento de todo el proyecto. Su diseño integró las mejores partes de los modelos pasados y agregó un mecanismo de atención temporal para mejorar la selección de características relevantes dentro de cada ventana EMG.

La incorporación de la CNN permitió recuperar la capacidad de extraer características locales entre canales, algo que había mostrado beneficios desde el Modelo 2.

La BiLSTM mantuvo la capacidad de analizar dependencias temporales en ambas direcciones, como se había observado en el Modelo 3. Finalmente, el mecanismo de attention permitió tener mayor peso a los instantes temporales más importantes.

El Modelo 4 alcanzó una accuracy en test de 89.34%, superando al Modelo 3 por 9.72 puntos porcentuales. También redujo el MAE a 0.2125 y la varianza a 3.1413, lo que demuestra un comportamiento más preciso y estable. Además, el reporte de clasificación mostró métricas altas en todas las clases, con un weighted F1-score de 0.8931 y un macro F1-score de 0.8752. Estos resultados confirman que la arquitectura CNN + BiLSTM + Attention es la propuesta más sólida del proyecto.

12. COMPARATIVA ENTRE MODELO 1 (LSTM), EL MODELO 2 (CNN + LSTM), EL MODELO 3 (BiLSTM + DATA AUGMENTATION + REBALANCEO DE CLASES) Y EL MODELO 4 (CNN + BiLSTM + ATTENTION)

Con el objetivo de evaluar la evolución del desempeño a lo largo de este proyecto, se llevó a cabo un análisis comparativo detallado entre las cuatro arquitecturas desarrolladas durante el proyecto:

1. Modelo LSTM unidireccional
2. Modelo con una arquitectura híbrida CNN + LSTM
3. Modelo BiLSTM reforzado mediante data augmentation y rebalanceo explícito de clases
4. Modelo CNN + BiLSTM + Attention

Cada una de estas propuestas representa un incremento progresivo en complejidad, capacidad de representación y tratamiento de las características espacio-temporales presentes en las señales EMG.

Métrica	Modelo 1 (LSTM)	Modelo 2 (CNN + LSTM)	Modelo 3 (BiLSTM + Data augmentation + rebalanceo de clases)	Modelo 4 (CNN + BiLSTM + Attention)
Accuracy (Test)	69.94%	74.38%	79.62%	89.34%
MAE (Test)	1.0109	0.8282	0.6412	0.2125
Bias (Test)	-0.0570	-0.1222	0.0114	-0.0580
Varianza (Test)	3.9233	3.7161	3.6433	3.1413
Loss final (Train)	0.4037	0.3124	0.0992	0.0148

Figura 17. Tabla comparativa de métricas Modelo 1 basado en LSTM vs Modelo 2 basado en CNN + LSTM vs Modelo 3 basado en BiLSTM, data augmentation y rebalanceo de clases vs Modelo 4 basado en CNN + BiLSTM + Attention.

Como podemos observar en la Figura 17, el rendimiento del sistema mejora conforme se incorporan componentes más especializados para procesar señales EMG. El Modelo 1 alcanzó un accuracy de 69.94%, funcionando como línea base inicial, aunque con limitaciones importantes para distinguir gestos similares y clases con menor representación. Después, el Modelo 2 aumentó el accuracy a 74.38% gracias a la incorporación de un bloque convolucional 1D, lo que permitió extraer características locales entre los canales EMG antes del procesamiento temporal.

Después, el Modelo 3 alcanzó un accuracy de 79.62%, representando una mejora al integrar una BiLSTM, data augmentation dirigido y class weights. Sin embargo, el mayor salto de desempeño se obtuvo con el Modelo 4, que alcanzó un accuracy de 89.34%, superando al Modelo 3 por 9.72 puntos porcentuales y al Modelo 1 por 19.40 puntos porcentuales.

La mejora del Modelo 4 está alineada con estudios recientes que han demostrado la utilidad de integrar redes convolucionales, modelos recurrentes y mecanismos de atención para mejorar el reconocimiento de gestos basado en señales sEMG [6], [7], [8], [9], [10]. Además, la disminución progresiva del error absoluto medio (MAE) confirma que las predicciones se acercan cada vez más a las etiquetas reales. El MAE pasó de 1.0109 en el Modelo 1 a 0.8282 en el Modelo 2, después a 0.6412 en el Modelo 3 y finalmente a 0.2125 en el Modelo 4. Esto indica que cuando el modelo se equivoca, sus errores tienden a estar mas cercanos de la clase correcta.

La varianza también disminuyó de forma constante entre modelos, pasando de 3.9233 en el Modelo 1 a 3.1413 en el Modelo 4. Esto muestra que las predicciones del modelo final son menos dispersas y más estables. En cuanto al bias, los valores se mantuvieron cercanos a cero en todos los modelos, aunque el Modelo 4 obtuvo un valor de -0.0580, lo que indica una ligera tendencia a subestimar algunas clases.

11. CONCLUSIÓN

El presente proyecto desarrolló un sistema de clasificación de gestos de la mano basado en señales EMG multicanal utilizando arquitecturas de deep learning, evaluando progresivamente cuatro modelos distintos e introduciendo mejoras tanto a nivel arquitectónico como de preparación de datos.

En la primera etapa, el Modelo 1 (LSTM unidireccional) permitió establecer una línea base funcional y ver la dificultad que había al intentar distinguir patrones musculares similares. Aunque alcanzó un desempeño aceptable de 69.94% de accuracy, presentó limitaciones importantes en la clasificación de algunas clases.

Después, el Modelo 2 (CNN + LSTM) incorporó convoluciones 1D para capturar relaciones espaciales entre los canales EMG. Esta modificación mejoró el modelo hasta 74.38% de accuracy. Sin embargo, las clases minoritarias continuaron siendo un problema.

Después, el Modelo 3 (BiLSTM + Data augmentation + Rebalanceo de clases) integró una arquitectura bidireccional y un tratamiento para el desbalance mediante oversampling y class weights. Este enfoque logró un accuracy de 79.62% y mejoró el reconocimiento de clases como la 1 y 7.

Finalmente, el Modelo 4 (CNN + BiLSTM + Attention) obtuvo el mejor desempeño de todo el proyecto, alcanzando un accuracy de 89.34% en el conjunto de prueba. Esta arquitectura integró las fortalezas de los modelos anteriores: la extracción espacial de la CNN, el análisis temporal bidireccional de la BiLSTM y un mecanismo de atención para identificar los instantes más relevantes de cada ventana EMG. Esta combinación hizo que el modelo lograra una reducción del MAE hasta 0.2125, una varianza menor de 3.1413 y una pérdida final de entrenamiento de 0.0148.

Los resultados obtenidos permiten concluir que la clasificación de gestos mediante señales EMG requiere una representación del espacio y tiempo de manera más completa. Entonces podemos decir que lo que aprendimos de la implementación de este proyecto es principalmente que:

- Las mejoras arquitectónicas deben responder a las limitaciones observadas en modelos anteriores.
- La combinación de CNN y modelos recurrentes permite capturar mejor las relaciones temporales y espaciales de las señales EMG.
- La bidireccionalidad ayuda a modelar la evolución completa de la activación muscular.
- El rebalanceo de clases es fundamental cuando existen clases con poca representación.
- Los mecanismos de attention permiten mejorar la selección de información relevante dentro de cada ventana temporal.

Además del aporte técnico, los resultados obtenidos en este proyecto muestran claramente el potencial que tienen los modelos de deep learning en aplicaciones clínicas, biomédicas e industriales basadas en señales EMG. Estas arquitecturas no solo permiten identificar patrones musculares complejos, sino que también pueden hacerlo aun cuando existe ruido fisiológico, variabilidad entre personas o similitud entre gestos, lo cual es una condición típica de este tipo de señales.

Gracias a esto, se abren posibilidades reales para desarrollar sistemas más precisos y accesibles, como prótesis mioeléctricas que respondan mejor al usuario, herramientas de rehabilitación adaptadas a cada paciente, interfaces más intuitivas y mecanismos de control muscular para robótica asistiva [3], [4], [5]. Además, la literatura reciente confirma que las arquitecturas híbridas con CNN, LSTM, BiLSTM, TCN y mecanismos de atención representan una línea de trabajo importante para mejorar el reconocimiento de gestos basado en señales sEMG [6], [7], [8], [9], [10].

Referencias

- [1] Krilova, N., Kastalskiy, I., Kazantsev, V., Makarov, V., & Lobov, S. (2018). EMG Data for Gestures [Dataset]. UCI Machine Learning Repository. <https://doi.org/10.24432/C5ZP5C>.
- [2] CNN-LSTM model for Time Series Forecasting. (n.d.). EmergentMind. <https://www.emergentmind.com/topics/cnn-lstm-model-for-time-series-forecasting>
- [3] De Jonge, S., Potters, W. V., & Verhamme, C. (2024). Artificial intelligence for automatic classification of needle EMG signals: A scoping review. *Clinical Neurophysiology*, 159, 41–55. <https://doi.org/10.1016/j.clinph.2023.12.134>
- [4] Meta. (n.d.). EMG Wristbands and Technology. Meta Emerging Tech. <https://www.meta.com/emerging-tech/emg-wearable-technology/>
- [5] Joshi, D. C., Kumar, P., Joshi, R. C., & Mitra, S. (2024). AI-enhanced analysis to investigate the feasibility of EMG signals for prosthetic hand force control incorporating anthropometric measures. *Prosthesis*, 6(6), 1459–1478. <https://doi.org/10.3390/prosthesis6060106>
- [6] L. Wang, J. Fu, B. Zheng and H. Zhao, "Research on sEMG-based gesture recognition using the Attention-based LSTM-CNN with Stationary Wavelet Packet Transform," 2022 4th International Conference on Advances in Computer Technology, Information Science and Communications (CTISC), Suzhou, China, 2022, pp. 1-6, <https://doi.org/10.1109/CTISC54888.2022.9849743>
- [7] J. Shin, A. S. M. Miah, S. Konnai, S. Hoshitaka and P. Kim, "Electromyography-Based Gesture Recognition With Explainable AI (XAI): Hierarchical Feature Extraction for Enhanced Spatial-Temporal Dynamics," in *IEEE Access*, vol. 13, pp. 88930-88951, 2025, <https://doi.org/10.1109/ACCESS.2025.3569899>
- [8] W. Ma, G. Song, Q. Zeng, H. Zhang, M. Zou and Z. Zhao, "FFCSLT: A Deep Learning Model for Traffic Police Hand Gesture Recognition Using Surface Electromyographic Signals," in *IEEE Sensors Journal*, vol. 24, no. 8, pp. 13640-13655, 15 April 2024, <https://doi.org/10.1109/JSEN.2024.3371588>
- [9] J. Guo and Z. Li, "A Continuous Hand Movement Recognition Method for sEMG Signals Based on BiLSTM Network and Attention Mechanism," 2023 5th International Conference on Robotics, Intelligent Control and Artificial Intelligence (RICAI), Hangzhou, China, 2023, pp. 1160-1164, <https://doi.org/10.1109/RICAI60863.2023.10489184>
- [10] H. Le, G. M. Spinks, M. i. h. Panhuis and G. Alici, "Cross-Day Myoelectric Gesture Recognition with Hybrid Multistream CNN-Bidirectional LSTM," 2025 IEEE International Conference on Mechatronics (ICM), Wollongong, Australia, 2025, pp. 1-6, <https://doi.org/10.1109/ICM62621.2025.10934890>
- [11] T. Mucci, What is data leakage in machine learning?, 2024, IBM. <https://www.ibm.com/think/topics/data-leakage-machine-learning>
- [12] Anon_Swe. (2018, January 28). SciKit-Learn: Avoiding data leakage during Cross-Validation. Stack Overflow. <https://stackoverflow.com/questions/48482440/scikit-learn-avoiding-data-leakage-during-cross-validation>