

Clasificación de gestos de mano mediante señales EMG utilizando redes LSTM

De Mónica Monserrat Martínez Vásquez | A01710965

Inteligencia artificial avanzada para la ciencia de datos I (Gpo 101)

Fecha: 09/11/2025

1. INTRODUCCIÓN

La electromiografía superficial (sEMG) es una técnica ampliamente utilizada en biomecánica, neuroingeniería y rehabilitación para analizar la actividad eléctrica producida por los músculos durante la ejecución de diferentes movimientos. Su naturaleza multicanal, su alta variabilidad fisiológica y la presencia de ruido convierten la clasificación automática de gestos basados en EMG en un problema desafiante que requiere métodos de procesamiento avanzados capaces de capturar relaciones temporales y espaciales complejas dentro de la señal.

En los últimos años, las arquitecturas de aprendizaje profundo han demostrado un rendimiento superior en tareas relacionadas con la interpretación de biosenales, gracias a su capacidad para aprender representaciones jerárquicas directamente a partir de los datos. Modelos como las redes LSTM, CNN y sus variantes híbridas han mostrado buenos resultados en la detección de patrones musculares no lineales, la identificación de movimientos específicos y la mejora de la robustez frente a la variabilidad de cada sujeto. En este contexto, la clasificación de gestos de la mano basados en señales EMG representa un caso de estudio relevante tanto para la investigación científica como para aplicaciones reales en interfaces humano-máquina, control de prótesis, rehabilitación asistida y tecnologías biomédicas emergentes.

El presente proyecto tiene como objetivo desarrollar, entrenar y comparar diferentes arquitecturas de deep learning para la clasificación de gestos a partir del dataset público “EMG Data for Gestures”, obtenido mediante el brazalete Myo Armband. Se implementaron tres modelos principales:

1. Una red LSTM unidireccional como línea base,
2. Un modelo híbrido CNN + LSTM para mejorar la extracción de características espaciales
3. Una arquitectura BiLSTM combinada con técnicas de data augmentation y rebalanceo de clases, diseñada para abordar directamente las deficiencias observadas en los experimentos iniciales.

Cada modelo fue entrenado y evaluado utilizando un pipeline completo de preparación de datos, normalización, segmentación mediante ventanas deslizantes y partición estratificada. Adicionalmente, durante el análisis de las curvas de pérdida y precisión se observó un comportamiento altamente progresivo, estable y libre de oscilaciones en algunos modelos, lo que sugiere que un mayor número de épocas habría permitido continuar mejorando el desempeño de los modelos. Sin embargo, debido a las limitaciones computacionales de los dispositivos y GPUs disponibles durante el entrenamiento, se estableció un máximo de 200 épocas como límite práctico. A pesar de ello, los modelos lograron converger adecuadamente y mostrar tendencias claras de mejora, indicando el potencial de seguir optimizándose bajo condiciones de cómputo más favorables.

A lo largo del reporte se documentan los fundamentos, la metodología de implementación, los análisis comparativos y las conclusiones derivadas del proceso experimental. Este trabajo demuestra el potencial de las EMG y el deep learning para aplicaciones reales en la industria biomédica, la robótica asistiva y el diseño de tecnologías de apoyo basadas en la actividad muscular humana.

2. SELECCIÓN DEL DATASET

Para el desarrollo del presente proyecto se seleccionó el conjunto de datos público “EMG Data for Gestures”[1], disponible en la plataforma Kaggle. Este dataset fue obtenido mediante el brazalete Myo Armband de la compañía Thalmic Labs, el cual cuenta con ocho sensores de electromiografía superficial (sEMG) puestos alrededor del antebrazo. Los datos representan la actividad eléctrica de los músculos durante la ejecución de diferentes gestos de la mano, tales como flexión, extensión, desviación radial y cubital, puño cerrado, palma extendida y mano relajada. Cada gesto se encuentra etiquetado mediante un número entero que se corresponde con las lecturas simultáneas de los ocho canales del brazalete.

La elección de este conjunto de datos responde a varios criterios técnicos y metodológicos. En primer

lugar, se trata de un dataset real, multicanal y de alta resolución temporal, adecuado para evaluar la capacidad de modelos profundos como LSTM de capturar patrones fisiológicos complejos. En segundo lugar, los archivos se encuentran organizados por sesiones y sujetos en formato de texto plano (.txt), lo cual facilita su lectura, inspección y manipulación utilizando bibliotecas estándar de análisis de datos en Python. Adicionalmente, la clasificación de gestos musculares constituye un caso representativo de aplicaciones biomédicas reales, donde la interpretación de señales EMG es un reto ampliamente estudiado.

Cada archivo del conjunto contiene diez columnas: una columna temporal (time), ocho canales de señal EMG (ch1 a ch8) y una columna de etiqueta (label). Las señales fueron muestreadas a alta frecuencia, permitiendo capturar los cambios rápidos de la actividad muscular. En la mayoría de los casos, las etiquetas permanecen constantes durante la ejecución de un gesto, lo cual posibilita segmentar los datos en ventanas temporales homogéneas para su tratamiento como muestras supervisadas. Cabe destacar que, a diferencia de datasets simplificados, este conjunto de datos presenta ruido fisiológico y variabilidad intersujeto, lo que incrementa la complejidad.

Antes del procesamiento, se realizó una inspección de consistencia para verificar que todos los archivos cumplieran con el mismo formato de columnas y se descartaron aquellos con estructuras anómalas o etiquetas no válidas. Después, se contabilizaron los registros disponibles por clase, confirmando un número equilibrado de ejemplos por gesto, lo cual permitió aplicar una estrategia de estratificación durante la partición de los conjuntos de entrenamiento, validación y prueba.

3. PREPARACIÓN DE DATOS

El conjunto de datos seleccionado consistía en múltiples archivos de texto plano que contenían registros secuenciales de señales EMG multicanal recopiladas mediante el sensor Myo Armband. Debido a la naturaleza fisiológica de las señales, se diseñó un proceso de preparación de datos con el objetivo de garantizar la calidad, consistencia y utilidad del dataset antes de su utilización en los modelos de deep learning.

3.1. LECTURA Y LIMPIEZA DE DATOS

La primera etapa del proyecto se centró en la lectura masiva de los archivos .txt, aprovechando la biblioteca glob para recorrer de forma recursiva toda la estructura de carpetas y consolidar cada registro en un único DataFrame. Durante este proceso, para cada archivo se

validó que cumpliera con los criterios mínimos de calidad necesarios para trabajar correctamente con señales EMG. En particular, se verificó que:

- El archivo contara exactamente con diez columnas (tiempo, los ocho canales EMG y la etiqueta)
- Todos los valores fueran numéricos y no hubiera caracteres inválidos
- La etiqueta fuera distinta de cero, descartando así segmentos vacíos o sin gesto
- Y que no existieran filas incompletas, corruptas o con un formato inconsistente.

Cualquier fila que incumpliera estas condiciones se eliminó. Esta depuración inicial fue fundamental para asegurar que todos los archivos compartieran una estructura bastante igual y, sobre todo, para evitar que errores de formato afectarían las etapas posteriores de normalización y segmentación temporal.

3.2. NORMALIZACIÓN POR CANAL

Las señales EMG suelen variar bastante entre sujetos, sesiones y hasta entre los mismos canales, debido tanto a factores fisiológicos como a diferencias en la adquisición. Para reducir esta variabilidad y facilitar el trabajo de los modelos, se aplicó una estandarización por canal utilizando StandardScaler. Con ello, cada canal EMG quedó ajustado a una media de 0 y una desviación estándar de 1.

$$x_{norm} = \frac{x - \mu}{\sigma}$$

Figura 5. Fórmula de normalización (o estandarización)

Esta normalización no altera la forma original de la señal, pero sí reduce su dispersión y la hace más uniforme entre canales. Esto resulta especialmente útil para modelos neuronales, ya que favorece la estabilidad durante el entrenamiento y acelera la convergencia al trabajar con rangos de magnitud más controlados.

3.3. SEGMENTACION MEDIANTE VENTANAS DESLIZANTES

Una vez normalizado el dataset completo, se procedió a la segmentación temporal aplicando una estrategia de sliding windows. Se establecieron ventanas de 200 muestras con un desplazamiento de 100 muestras entre una ventana y la siguiente.

Para asegurar que cada ventana representara un único gesto bien definido, solo se conservaron aquellas en las que todas las etiquetas internas coincidían. Este criterio permitió descartar transiciones entre gestos y

garantizó que cada fragmento fuera una unidad temporal coherente para su uso en clasificación supervisada.

Cada ventana generada corresponde a una matriz de $200 \text{ time steps} \times 8 \text{ canales EMG}$, lo que transformó las señales continuas en instancias independientes, adecuadas tanto para modelos recurrentes como para arquitecturas híbridas convolucional recurrentes.

3.4. DIVISIÓN ESTRATIFICADA DEL DATASET

Una vez generadas todas las ventanas, el conjunto se dividió en entrenamiento, validación y prueba utilizando `train_test_split` con estratificación. Las proporciones finales fueron:

- 80% para entrenamiento
- 10% para validación
- 10% para prueba

La estratificación se usó para mantener la proporción original de clases en cada subconjunto, algo importante debido a la presencia de clases minoritarias. Esto permitió ajustar hiperparámetros usando únicamente el conjunto de validación, mientras que el conjunto de prueba permaneció completamente independiente para evaluar la capacidad real de generalización del modelo y sus mejoras.

3.5. CONSTRUCCIÓN DE DATA LOADERS PARA ENTRENAMIENTO

Finalmente, cada subconjunto fue encapsulado en una clase personalizada llamada `EMGDataset`, construida a partir de la clase `Dataset` de PyTorch. Esta clase se encargó de convertir cada ventana en tensores, gestionar el acceso por índices y permitir una integración directa con los `DataLoader` durante el entrenamiento.

Cada `DataLoader` generó lotes de 64 ventanas seleccionadas aleatoriamente en cada época, lo que hizo posible entrenar mediante mini-batches. De esta manera, el flujo completo de datos quedó optimizado para entrenamientos prolongados y arquitecturas de mayor complejidad.

3.6. HIPERPARAMETROS GENERALES DE LOS MODELOS

A fin de garantizar una comparación objetiva entre las diferentes arquitecturas evaluadas, los tres modelos desarrollados (LSTM, CNN+LSTM y BiLSTM) compartieron un conjunto de hiperparámetros base que se mantuvieron constantes durante todo el proceso experimental. Estos hiperparámetros definen las condiciones de entrenamiento y permiten aislar el efecto

real de las modificaciones arquitectónicas introducidas en cada versión del modelo.

3.6.1. HIPERPARÁMETROS COMPARTIDOS EN LOS TRES MODELOS

- Número de épocas: 200
- Tamaño de batch: 64
- Optimizador: Adam
- Learning rate: 0.001
- Función de pérdida: `CrossEntropyLoss`
- Criterio de selección del mejor modelo: mayor validation accuracy alcanzada durante el entrenamiento
- Dispositivo de entrenamiento: GPU (colab)

El uso del optimizador Adam con learning rate fijo proporcionó una convergencia estable y consistente entre modelos, mientras que los 200 epochs permitieron observar tendencias claras sin alterar el presupuesto computacional disponible. El batch size de 64 se eligió como un punto intermedio que equilibraba eficiencia computacional y estabilidad del gradiente, permitiendo entrenar adecuadamente incluso en GPUs limitadas.

Se mantuvieron estos hiperparámetros constantes para que la comparación final reflejara únicamente las mejoras derivadas del diseño del modelo, sin ningún sesgo por cambios en las condiciones de entrenamiento.

4. MODELO 1: LSTM UNIDIRECCIONAL PARA CLASIFICACIÓN DE GESTOS EMG

Este primer modelo tiene una arquitectura basada en una red LSTM unidireccional, seleccionada como aproximación inicial debido a su capacidad para procesar series temporales multivariadas y modelar dependencias dinámicas presentes en señales EMG. El objetivo de este primer prototipo fue establecer una línea base sobre la cual desarrollar mejoras en el futuro.

Como ya mencionamos se basa en una arquitectura secuencial sencilla, diseñada como línea base para la clasificación de gestos EMG. El núcleo del modelo es una capa LSTM unidireccional, configurada con un `input_size` de 8 características correspondientes a los canales del brazalete MYO, un `hidden_size` de 64 unidades recurrentes y una única capa (`num_layers = 1`). Esta configuración permite capturar patrones temporales básicos presentes en la actividad muscular, mientras que un dropout del 30% ayuda a mitigar el sobreajuste. A la salida del LSTM se incorpora una capa totalmente conectada de 64 neuronas con activación ReLU, encargada de hacer la transformación de la representación secuencial en un espacio latente más compacto y no lineal. Posteriormente, se aplica

nuevamente un dropout del 30% para reforzar la regularización y mejorar la capacidad de generalización. Finalmente, el modelo concluye con una capa densa de 8 neuronas, cada una asociada a una de las clases de gestos. Esta arquitectura aprovecha la capacidad de la LSTM para capturar la dinámica muscular a lo largo de las ventanas temporales de 200 muestras, extrayendo características relevantes de cada gesto.

4.1. ENTRENAMIENTO Y CURVAS DE APRENDIZAJE




Figura 1. Curvas de entrenamiento del modelo 1 (LSTM)

Durante el entrenamiento se observó un descenso progresivo y estable de la función de pérdida, sin oscilaciones fuertes ni nada de comportamientos irregulares o raros. Este patrón, ilustrado en la Figura 1, sugiere que la red logró aprender representaciones consistentes a partir de las señales EMG, ajustando gradualmente sus parámetros sin evidencias de inestabilidad numérica o sobreajuste temprano. Paralelamente, la curva de exactitud en validación muestra que el modelo mantiene un incremento constante a lo largo de las épocas, estabilizándose alrededor del 71%.

El mejor desempeño alcanzado por el modelo corresponde a una accuracy de validación del 71.81%, mientras que la evaluación final en el conjunto de prueba arrojó una accuracy del 69.94%. Eso nos dice que el modelo es capaz de capturar ciertos patrones musculares relevantes, aunque podría mejorar.

4.2. EVALUACIÓN CUANTITATIVA

4.2.1. MÉTRICAS GLOBALES (TEST SET)




Figura 2. Métricas globales del Modelo 1 (LSTM)

La evaluación cuantitativa del Modelo 1 en el conjunto de prueba muestra un desempeño que podría considerarse moderado como podemos ver en la figura 2. Estos resultados (Figura 2), se aprecia que el error absoluto medio indica que, en promedio, el modelo se equivoca aproximadamente por una clase en sus predicciones.

El valor del sesgo, cercano a cero, nos dice que las predicciones no presentan una tendencia hacia la sobreestimación o subestimación de clases. Sin embargo, la varianza nos dice que hay una dispersión moderada de las predicciones, lo cual tiene sentido con la naturaleza ruidosa y muy variable de las señales EMG. En conjunto, estas métricas sugieren un comportamiento estable y bueno, aunque limitado en cuanto a capacidad de diferenciar entre gestos que son parecidos entre sí.

Reporte de clasificación:				
	precision	recall	f1-score	support
0	0.7622	0.8261	0.7929	2887
1	0.0000	0.0000	0.0000	249
2	0.5781	0.6141	0.5956	241
3	0.5391	0.5020	0.5199	247
4	0.5072	0.5645	0.5344	248
5	0.5531	0.5000	0.5252	250
6	0.5504	0.5657	0.5580	251
7	0.3846	0.3333	0.3571	15
accuracy			0.6994	4388
macro avg	0.4844	0.4882	0.4854	4388
weighted avg	0.6566	0.6994	0.6769	4388

Figura 3. Reporte de clasificación del Modelo 1 (LSTM)

El desempeño por clase, presentado en la Figura 3, muestra un comportamiento bastante desigual. La clase 0 (mano en reposo) domina el dataset y, como consecuencia, alcanza las métricas más altas (F1 = 0.7929), reflejando que el modelo logra identificar patrones de inactividad muscular. Sin embargo, las otras clases presentan problemas en su clasificación, por ejemplo:

- La clase 1 obtiene métricas de 0, indicando que el modelo no identificó bien ni un solo ejemplo de esta categoría. Esto puede deberse a que se parecen mucho los patrones electromiográficos con otras clases de gestos.
- La clase 7, con apenas 15 muestras en el test set, también muestra un rendimiento bastante bajo (F1 = 0.3571), se ve muy claro el desbalance que hay en la capacidad del modelo para prender gestos que están poco representados.

Las clases intermedias (como 2 a 6) muestran métricas moderadas y relativamente normales, con F1-scores entre 0.51 y 0.59, lo que sugiere que el modelo

captura parcialmente sus características, pero aún tiene dificultades para separarlas realmente.

4.2.2. MATRIZ DE CONFUSIÓN




Figura 4. Matriz de confusión del test set del modelo 1 (LSTM)

La matriz de confusión, mostrada en la Figura 4, confirma varios de los patrones detectados previamente. En primer lugar, el modelo presenta una fuerte tendencia a sobredetectar la clase 0. Esto nos dice que la señal de reposo predomina la representación aprendida por el modelo, posiblemente porque es de los gestos más representados en el dataset, es decir, hay más datos.

Además, la matriz nos muestra que hay veces que el modelo confunde gestos entre ellos, por ejemplo cuando habla de flexión y extensión (clase 3 y 4) o cuando habla de desviación radial y desviación cubital (clase 5 y 6). Estas confusiones son esperables, ya que estos pares de gestos se parecen mucho hablando más en patrones electromiográficos, especialmente en la activación de grupos musculares vecinos.

Finalmente, la matriz confirma que el modelo no reconoce nunca la clase 1, ya que todos sus ejemplos fueron clasificados como clase 0. Esto nos recalca la incapacidad del LSTM unidireccional para extraer características distintivas de gestos que son menos representados, incluso con regularización y entrenamiento extendido.

5. CONCLUSIÓN DE LA PRIMERA VERSIÓN DEL MODELO

El análisis del Modelo 1 permitió darnos cuenta que hubo mucho desbalance significativo entre clases, esto afectó directamente la capacidad del modelo para aprender representaciones adecuadas de los gestos

minoritarios, favoreciendo a la tendencia de predecir la clase que está más representada y mejor identificada, la cual es la de reposo. Esto empeora porque hubo mucha similitud en los demás gestos, cuyos patrones electromiográficos presentan diferencias sutiles que resultan difíciles de distinguir mediante una arquitectura LSTM unidireccional simple.

Asimismo, el esquema de segmentación que esta basado en ventanas monoclasa, si reduce el ruido temporal, pero realmente no resuelve nada de la variabilidad baja de algunos gestos, lo que nos baja mucho la diversidad de los patrones que puede aprender el modelo. Esto nos muestra que una única capa LSTM de 64 unidades resulta insuficiente para capturar dependencias espaciotemporales complejas.

A pesar de estas limitaciones, el Modelo 1 alcanzó un desempeño aceptable y permitió confirmar la viabilidad del enfoque secuencial. Sin embargo, debido a que este modelo no puede reconocer algunas clases y se confunde entre gestos fisiológicamente iguales nos dice que es necesario ampliar la complejidad de la arquitectura. Esto nos lleva a intentar un modelo 2 mejorado que use capas convolucionales y tenga una mayor profundidad temporal.

6. MODELO 2: ARQUITECTURA HÍBRIDA CNN + LSTM PARA CLASIFICACIÓN DE GESTOS EMG (1ERA MEJORA)

Tras analizar las limitaciones del Modelo 1, particularmente su dificultad para distinguir gestos con patrones musculares similares y su incapacidad para modelar relaciones espaciales entre los canales EMG, se propuso una segunda aproximación basada en una arquitectura híbrida Convolutiva + LSTM (CNN+LSTM). Este tipo de modelo es ampliamente utilizado en señales fisiológicas multicanal debido a su habilidad para extraer características espacialmente relevantes antes de procesar la secuencia temporal completa [2].

El objetivo principal es extraer características espaciales locales antes del modelado temporal. Por esto usamos la convolución ya que nos permite identificar correlaciones entre canales adyacentes, filtrar ruido y generar representaciones más ricas para la etapa recurrente. También dejamos la normalización por lotes, el max pooling y el dropout para intentar contribuir a estabilizar el aprendizaje y mejorar la generalización. Al proveer una representación refinada de la señal, la CNN facilita que la LSTM capture patrones temporales complejos y, en consecuencia, aumenta significativamente la capacidad discriminativa del

modelo frente a gestos altamente similares en el espacio fisiológico.

6.1. MEJORAS Y CAMBIOS

El Modelo 2 adopta una arquitectura híbrida compuesta por tres bloques principales: un módulo convolucional, un módulo recurrente y una cabeza densa de clasificación final. Entonces vamos paso por paso a explicar cada una de ellas:

6.1.1. BLOQUE CONVOLUCIONAL (CNN 1D)

Este bloque recibe la señal con forma y aplica dos etapas de convolución secuencial. La primera capa Conv1D transforma los 8 canales originales en 32 mapas de características utilizando un kernel de tamaño 3, seguida de “Batch Normalization”, activación ReLU y un dropout del 20% para reducir sobreajuste. La segunda convolución es de 64 filtros, también seguida de ReLU y un MaxPool1D con factor 2, que reduce la resolución temporal y enfatiza en los patrones que nos importan que son los más relevantes para intentar hacer una mejora respecto al modelo 1. Este bloque permite aprender correlaciones locales entre canales, algo que el Modelo 1 no podía capturar.

6.1.2. BLOQUE RECURRENTE (LSTM)

La salida convolucional se “reordena” para dársela a una LSTM configurada con un input_size de 64 y un hidden_size de 64. Esta red recurrente identifica dependencias temporales a lo largo de las 200 muestras de cada ventana, donde se aprovecha la representación que se obtuvo de la CNN.

6.1.3. CABEZA DENSA DE CLASIFICACIÓN

Finalmente, las características aprendidas se pasan a un perceptrón de dos capas: una capa lineal de 64 unidades con activación ReLU y dropout del 30%, seguida de una capa lineal final de 8 neuronas correspondientes a las clases de gestos de nuestro dataset. Este bloque produce las probabilidades de clasificación a partir del embedding temporal generado por la LSTM.

6.2. ENTRENAMIENTO Y CURVAS DE APRENDIZAJE




Figura 5. Curvas de entrenamiento del modelo 2 (CNN + LSTM)

El proceso de entrenamiento del Modelo 2 evidenció un comportamiento considerablemente más estable que el observado en el Modelo 1. Tal como se muestra en la Figura 5, la función de pérdida presentó un descenso progresivo, lo que indica que la combinación CNN–LSTM facilitó un aprendizaje más controlado y robusto.

De manera paralela, la curva de exactitud en validación alcanzó valores parecidos a los mejores registrados en el Modelo 1; sin embargo, lo hizo manteniendo una evolución más uniforme y con menos variabilidad entre épocas.

6.3. EVALUACIÓN CUANTITATIVA

6.3.1. MÉTRICAS GLOBALES (TEST SET)




Figura 6. Métricas globales del Modelo 2 (CNN + LSTM)

El desempeño cuantitativo del Modelo 2 mostró mejoras con respecto al Modelo 1. Como se observa en la Figura 6, el modelo alcanzó una accuracy de validación de 71.81% y en el conjunto de prueba una de 74.38%, lo que representa un incremento de 4.44 puntos porcentuales. Además, métricas como el MAE, bias y varianza son un poco mejores ya que no tienen error promedio y tienen una dispersión menor entre cada clase.

Reporte de clasificación:				
	precision	recall	f1-score	support
0	0.7889	0.8608	0.8233	2887
1	0.3662	0.1044	0.1625	249
2	0.7235	0.6515	0.6856	241
3	0.6135	0.6235	0.6185	247
4	0.6233	0.5403	0.5788	248
5	0.6360	0.6360	0.6360	250
6	0.6544	0.5657	0.6068	251
7	0.4118	0.4667	0.4375	15
accuracy			0.7438	4388
macro avg	0.6022	0.5561	0.5686	4388
weighted avg	0.7244	0.7438	0.7285	4388

Figura 7. Reporte de clasificación del Modelo 2 (CNN + LSTM)

Además, los resultados del reporte de clasificación, presentados en la Figura 7, muestran una mejora significativa en el rendimiento por clase respecto al Modelo 1. El macro F1-score aumentó de 0.4854 a 0.5686, mientras que el weighted F1-score pasó de 0.6769 a 0.7285, lo que demuestra un equilibrio entre clases, algo que estábamos buscando.

Aunque la clase 0 continúa siendo la mejor precisión de todas las clases. El Modelo 2 logra una mejora en varias clases clave, incluyendo flexión, extensión, desviaciones radial y cubital, y palma extendida. La clase 1 sigue siendo problemática debido a su baja representatividad, aunque, a diferencia del Modelo 1, el Modelo 2 comienza a mostrar predicciones correctas.

4.3.2. MATRIZ DE CONFUSIÓN




Figura 8. Matriz de confusión del test set del modelo 2 (CNN + LSTM)

La Figura 8 evidencia una reducción en los patrones de confusión que afectaban al Modelo 1. El Modelo 2 disminuye la tendencia a clasificar mal algunos gestos como la clase 0, lo que sugiere una mayor discriminación

muscular y un aprendizaje más equilibrado entre categorías. Asimismo, se observa una mejor identificación en las clases 2 a 6.

A pesar de estas mejoras, la clase 7 sigue siendo difícil de aprender debido a sus pocas muestras (15 muestras), lo que limita la capacidad del modelo para aprender sus patrones característicos. Aun así, el modelo muestra una separación más clara entre gestos similares fisiológicamente hablando.

7. CONCLUSIÓN DE LA SEGUNDA VERSIÓN DEL MODELO

El análisis del Modelo 2 confirma que cuando integramos un bloque convolucional antes del módulo recurrente mejoró un poco respecto al enfoque puramente secuencial del Modelo 1. La combinación de la CNN y una LSTM nos ayudó a tener una mejor capacidad discriminativa, un aumento significativo en la accuracy de prueba y una reducción tanto del MAE como de la varianza.

No obstante, algunas limitaciones persisten. La clase 1 continúa siendo difícil de reconocer, lo que sugiere que aún tenemos un problema presente de desbalance. Del mismo modo, los gestos que tenemos menos muestras como la clase 7 mantienen un rendimiento bajo. Esto nos dice que aunque la arquitectura CNN+LSTM mejora la representación espacio temporal, todavía podemos mejorar la robustez del modelo especialmente las clases con baja frecuencia.

El Modelo 2 representa un avance significativo frente al primer enfoque pero para mejorar las licitaciones mencionadas previamente, intentamos mejorar el modelo incorporando una arquitectura BiLSTM y estrategias explícitas de data augmentation, con el objetivo de mejorar la representación temporal bidireccional y abordar de manera más directa la falta de ejemplos en clases con pocas muestras.

8. MODELO 3: ARQUITECTURA BiLSTM CON DATA AUGMENTATION Y REBALANCEO DE CLASES (2DA MEJORA)

Tras evaluar el desempeño del Modelo 2, se identificaron dos limitaciones que impedían mejorar la clasificación de ciertos gestos:

- Bajo rendimiento en clases minoritarias, particularmente en las clases 1 y 7, que en el dataset original tenían únicamente 249 y 15 muestras, respectivamente. Este desbalance provocaba que los modelos pasados tendieran a

clasificar estos gestos como clase 0, afectando incluso el rendimiento general del modelo.

- Dificultad para capturar patrones temporales complejos, ya que una arquitectura unidireccional sigue una sola trayectoria temporal y no logra modelar transiciones musculares más discretas que ocurren antes y después del gesto principal.

Además, durante el análisis comparativo entre el Modelo 1 y el Modelo 2 se observó que el desbalance extremo del dataset estaba afectando bastante la capacidad de generalización, ya que incluso al mejorar la arquitectura (CNN+LSTM), las clases 1 y 7 seguían siendo mal clasificadas o ignoradas por completo. Esto llevó a la conclusión de que era necesario intervenir explícitamente en la estructura de los datos con técnicas de data augmentation.

Por ello, el Modelo 3 incorpora tres mejoras fundamentales:

- BiLSTM bidireccional
- Data augmentation dirigido
- Class weights

Este conjunto de cosas nos permitió construir una arquitectura más robusta y equilibrada, incrementando así la capacidad discriminativa del modelo y reduciendo la confusión entre señales musculares parecidas.

8.1. MEJORAS Y CAMBIOS

8.1.1. USO DE UNA BiLSTM

Las señales EMG presentan dinámicas temporales complejas donde la anticipación y el decaimiento de la activación muscular contienen información relevante. Mientras que una LSTM unidireccional únicamente considera el pasado, una BiLSTM incorpora simultáneamente el contexto temporal precedente y subsecuente. Esto permite:

- Detectar transiciones musculares con mayor claridad
- Capturar movimientos suaves que requieren información bidireccional
- Reducir confusiones entre gestos fisiológicamente parecidos porque esas diferencias se manifiestan de manera temporal.

8.1.2. DATA AUGMENTATION EN CLASES 1 Y 7

Uno de los principales problemas del modelo 1 y el modelo 2 es que el dataset original presentaba un desbalance ya que la clase 1 contaba con 249 muestras, mientras que la clase 7 tenía únicamente 15 muestras.

Esto causaba que los modelos detectan mejor las clases que tenían más muestras o que eran mayoritarias como la clase 0.

Pensando en esto, se aplicó oversampling dirigido, duplicando las ventanas pertenecientes a las clases más pequeñas, incrementando la exposición del modelo a los patrones reales de estas clases con menores muestras.

8.1.3. USO DE CLASS WEIGHTS

Debido a que el desbalance que tenemos en nuestro dataset es muy marcado. Se incorporaron pesos por clase, asignando valores mayores a las clases 1 y 7 [1.0, 1.5, 1.0, 1.0, 1.0, 1.0, 2.0].

Esto lo que hace es que penaliza más los errores cometidos en clases con menos muestras y refuerza su aprendizaje, complementando así el data augmentation y estabilizando la contribución de cada clase al proceso de optimización.

8.1.4. ARQUITECTURA NUEVA

La arquitectura del Modelo 3 introduce una estructura bastante más robusta que las versiones pasadas. El núcleo del modelo es un bloque BiLSTM de dos capas, configurado con un tamaño de entrada de ocho canales EMG, un espacio oculto de 64 unidades por dirección y una tasa de dropout del 30%. La bidireccionalidad permite que el modelo procese al mismo tiempo la información temporal hacia adelante y hacia atrás. Esto es importante ya que en problemas como estos necesitamos tener cotexto anterior y posterior ya que nos da elementos esenciales para la correcta discriminación entre gestos.

Sobre la salida del bloque recurrente se implementa una cabeza densa de clasificación para transformar esta representación bidireccional en algo más compacto. Este componente consta de una capa lineal de 64 unidades con activación ReLU, acompañada de un dropout del 30% para reducir el sobreajuste. Finalmente, una segunda capa lineal proyecta este espacio latente hacia las ocho clases posibles del problema, generando las probabilidades correspondientes a cada gesto. Esta nueva arquitectura nos permite incrementar la capacidad del modelo para diferenciar gestos fisiológicamente parecidos y para aprender patrones que nos son tan visibles o notables en las señales EMG multicanal.

8.2. ENTRENAMIENTO Y CURVAS DE APRENDIZAJE




Figura 9. Curvas de entrenamiento del modelo 3 (BiLSTM + Data augmentation + rebalanceo de clases)

Las curvas de aprendizaje del Modelo 3, presentadas en la Figura 9, evidencian un proceso de entrenamiento más estable que el pasado y constante. La función de pérdida muestra un descenso suave y continuo sin indicios de sobreajuste, lo que confirma que la arquitectura bidireccional, junto con la regularización aplicada, permitió un aprendizaje bastante controlado a lo largo de las épocas. La exactitud en validación incrementa de manera sostenida hasta aproximarse al 80%. Este comportamiento es más robusto que el observado en los modelos pasados.

Un factor clave detrás de esta mejora fue la estrategia de data augmentation dirigida, que consistió en duplicar las ventanas de las clases 1 y 7. Esta intervención aumentó su presencia durante el entrenamiento sin alterar nada de la estructura fisiológica de las señales. Esto lo que causó es que el modelo pudo recibir más cantidad de muestras y aprender mejor los patrones de esas clases en particular. La evolución positiva tanto de la pérdida como de la exactitud de validación demuestra que el oversampling, junto con el uso de class weights, nos ayudo bastante a mejorar la estabilidad del entrenamiento y la discriminación de clases minoritarias.

Por último podemos observar que debido a la curva que tenemos de pérdida, podríamos decir que si le ponemos más épocas a nuestro modelo podría mejorar aún más ya que el accuracy y la pérdida son bastante constantes y progresivas. Pero por limitaciones en la GPU de los dispositivos que usamos para entrenar al modelo solo pusimos las 200 épocas.

8.3. EVALUACIÓN CUANTITATIVA

8.3.1. MÉTRICAS GLOBALES (TEST SET)

Entrenamiento finalizado.
Mejor accuracy de validación: 80.05%

Accuracy en test set: 79.62%
MAE (Test): 0.6412
Bias (Test): 0.0114
Varianza (Test): 3.6433

Figura 10. Métricas globales del Modelo 3 (BiLSTM + Data augmentation + rebalanceo de clases)

Los resultados cuantitativos del Modelo 3, mostrados en la Figura 10, reflejan el mayor desempeño alcanzado en todo el proyecto. El modelo obtuvo una accuracy de validación del 80.05% y una accuracy en el conjunto de prueba del 79.62%, superando a las arquitecturas anteriores. Además, los valores de MAE, bias y varianza indican un modelo relativamente equilibrado y estable. El sesgo es prácticamente, esto demuestra que el modelo no favorece de ninguna manera a ninguna clase, mientras que la disminución del MAE no dice que las predicciones son más cercanas a las etiquetas reales. En resumen, estos indicadores nos confirman que al usar una BiLSTM bidireccional, junto con técnicas de rebalanceo de datos, si nos sirvió para poder obtener un modelo más preciso y con una mejor generalización.

Reporte de clasificación:				
	precision	recall	f1-score	support
0	0.8577	0.8265	0.8418	2887
1	0.7145	0.8494	0.7761	498
2	0.7208	0.7925	0.7549	241
3	0.6761	0.6761	0.6761	247
4	0.7108	0.7108	0.7108	249
5	0.6553	0.6948	0.6745	249
6	0.7260	0.6335	0.6766	251
7	0.8235	0.9333	0.8750	30
accuracy			0.7962	4652
macro avg	0.7356	0.7646	0.7482	4652
weighted avg	0.7996	0.7962	0.7968	4652

Figura 11. Reporte de clasificación del Modelo 3 (BiLSTM + Data augmentation + rebalanceo de clases)

En cuanto al reporte de clasificación mostrado en la Figura 11 nos muestra que la mejora que realizamos fue muy buena en términos generales para todas las clases, justamente eliminando el problema de desbalanceo que teníamos presente en las versiones pasadas del modelo. El Modelo 3 alcanzó valores de F1-score superiores a 0.67 en todas las categorías, lo que representa un equilibrio entre clases bastante bueno para un problema de señales EMG.

Podemos destacar tres cosas:

- La clase 1, la cual era la más problemática en los modelos anteriores, alcanzó un recall de 0.8494, lo cual se puede atribuir al oversampling

dirigido y al uso de class weights que se aplicaron para este modelo.

- La clase 7, en el Modelo 1 tenía un F1 de 0.35, pero con esta nueva arquitectura obtuvo un F1-score de 0.875. Lo que sería la mayor mejora registrada en todo el proyecto.
- Todas las clases presentan métricas altas, con mejoras en precisión, recall y F1-score.

8.3.2. MATRIZ DE CONFUSIÓN




Figura 12. Matriz de confusión del test set del modelo 3 (BiLSTM + Data augmentation + rebalanceo de clases)

La matriz de confusión, presentada en la Figura 12, sustenta lo que acabamos de observar y analizar en la sección pasada porque nos muestra que el Modelo 3 tiene una separación buena y efectiva entre las clases 1, 2, 3, 4, 5 y 7, con una cantidad mínima de falsos positivos. Destacando la clase 7, donde el modelo realizó 28 aciertos de 30 muestras, demostrando que el rebalanceo del dataset y la arquitectura bidireccional permitieron capturar mejor los patrones distintivos que antes no se podían detectar.

La clase 0, aunque sigue siendo aún la más representada, ya no absorbe predicciones incorrectas con la misma frecuencia que en los Modelos 1 y 2. Sin embargo la clase 6 aun tiene cierta confusión entre las clases 0 y 3, ya que tienen bastante similitud fisiológica en la activación muscular.

Todo esto mencionado anteriormente nos demuestra que la nueva arquitectura BiLSTM ayuda mucho en la captura de las dinámicas temporales bidireccionales. Además, junto con las estrategias de rebalanceo aplicadas nos ayudaron a quitar las limitaciones que tenía nuestro dataset y permitir mejorar el aprendizaje de todas las categorías del problema.

9. CONCLUSIÓN DE LA TERCERA VERSIÓN DEL MODELO

El Modelo 3 fue la arquitectura con el rendimiento más alto y el comportamiento más estable entre todas las alternativas evaluadas. Su diseño abordó de manera directa dos limitaciones críticas observadas en los modelos pasados:

- La incapacidad para aprender clases minoritarias (como las clases 1 y 7, con 249 y apenas 15 muestras respectivamente)
- La insuficiencia de las arquitecturas unidireccionales para capturar patrones temporales complejos característicos de las señales EMG.

Entonces, la incorporación de una BiLSTM bidireccional de dos capas, combinada con regularización mediante dropout, nos dio la posibilidad de modelar dependencias temporales tanto hacia adelante como hacia atrás, mejorando la detección de patrones con transiciones musculares sutiles o discretas que eran las que más problema tenían en las versiones anteriores. Además, la estrategia de oversampling dirigido tuvo un impacto fuerte. Esta fue implementada tras observar que los modelos 1 y 2 se inclinaban más hacia clases mayoritarias debido a que teníamos un desbalance extremo en el dataset. La duplicación de las muestras de las clases 1 y 7, complementada con un esquema de class weights, corrigió este desequilibrio y permitió que el modelo aprendiera mejores representaciones de estas categorías difíciles de distinguir.

En resumen, el Modelo 3 alcanzó mejoras significativas, resolviendo completamente el problema crítico de la clase 1 y transformando la clase 7, que antes era poco reconocible, en una de las más precisas del modelo. Las curvas de aprendizaje mostraron un entrenamiento estable, mientras que la métrica de prueba alcanzó un 79.62% de accuracy, el valor más alto de todo el proyecto. Este desempeño se reflejó y mantuvo también en indicadores como MAE, bias y varianza.

10. COMPARATIVA ENTRE MODELO 1 (LSTM), EL MODELO 2 (CNN + LSTM) Y EL MODELO 3 (BiLSTM + DATA AUGMENTATION + REBALANCEO DE CLASES)

Con el objetivo de evaluar la evolución del desempeño a lo largo de este proyecto, se llevó a cabo un análisis comparativo detallado entre las tres arquitecturas desarrolladas durante el proyecto:

1. Modelo LSTM unidireccional

2. Modelo con una arquitectura híbrida CNN + LSTM
3. Modelo BiLSTM reforzado mediante data augmentation y rebalanceo explícito de clases.

Cada una de estas propuestas representa un incremento en complejidad y capacidad de representación.

Métrica	Modelo 1 (LSTM)	Modelo 2 (CNN + LSTM)	Modelo 3 (BiLSTM + Data augmentation + rebalanceo de clases)
<i>Accuracy (Test)</i>	69.94%	74.38%	79.62%
<i>MAE (Test)</i>	1.0109	0.8282	0.6412
<i>Bias (Test)</i>	-0.0570	-0.1222	0.0114
<i>Varianza (Test)</i>	3.9233	3.7161	3.6433
<i>Loss final (Train)</i>	0.4037	0.3124	0.0992

Figura 13. Tabla comparativa de métricas Modelo 1 basado en LSTM vs Modelo 2 basado en CNN + LSTM vs Modelo 3 basado en BiLSTM, data augmentation y rebalanceo de clases

Como podemos observar en la Figura 13 el rendimiento de cada modelo crece. El Modelo 1 alcanzó un accuracy de 69.94%, dándonos una línea base que estaba limitada por la falta de extracción espacial y por el desbalance presente en el dataset. Con la introducción de un bloque convolucional en el Modelo 2, el rendimiento aumentó a 74.38%, demostrando que esta nueva arquitectura permite capturar relaciones espacio-temporales mejor. Finalmente, el Modelo 3 logró un accuracy de 79.62%, representando un incremento total de +9.68 puntos porcentuales respecto al modelo inicial.

Además, la disminución progresiva del error absoluto medio (MAE) es otra evidencia de la mejora entre generaciones de modelos. El MAE pasó de 1.0109 en el Modelo 1, a 0.8282 en el Modelo 2, y finalmente a 0.6412 en el Modelo 3. Indicando que las predicciones del último modelo tienden a estar más cerca de la clase verdadera. De igual manera, la varianza también disminuyó en cada iteración, mostrando que el Modelo 3 produce predicciones con menos variabilidad. Y el bias no fue la excepción ya que revela que los Modelos 1 y 2 presentaban una ligera tendencia a subestimar la clase real, el Modelo 3 alcanzó un bias prácticamente nulo (0.0114). Esto nos dice que la arquitectura final es capaz de equilibrar, evitando favorecer a clases mayoritarias. En cuanto a la pérdida final de entrenamiento también

muestra un aumento. El Modelo 1 se quedó con una pérdida de 0.4037, mientras que el Modelo 2 redujo este valor a 0.3124 gracias a la mejor extracción de características. Pero, el salto más significativo se observa en el Modelo 3, cuya pérdida final bajó hasta 0.0992.

11. CONCLUSIÓN

El presente proyecto desarrolló un sistema de clasificación de gestos de la mano basado en señales EMG multicanal utilizando arquitecturas de deep learning, evaluando progresivamente tres modelos distintos e introduciendo mejoras tanto a nivel arquitectónico como de preprocesamiento.

En la primera etapa, el Modelo 1 (LSTM unidireccional) permitió establecer una línea base funcional y evidenciar las cosas que serían retadores del dataset que se escogió, principalmente el desbalance severo de clases y la dificultad para distinguir patrones musculares similares. Aunque alcanzó un desempeño aceptable (69.94% de accuracy), presentó fuertes limitaciones en clases con menos muestras en el dataset.

Posteriormente, el Modelo 2 (CNN + LSTM) introdujo convoluciones 1D para capturar relaciones espaciales entre canales EMG, logrando una mejora de 4.44 puntos porcentuales y reduciendo la confusión entre gestos. Sin embargo, las clases minoritarias continuaron siendo un problema.

Finalmente, el Modelo 3 (BiLSTM + Data augmentation + Rebalanceo de clases) incorporó una arquitectura más profunda, dependencias temporales bidireccionales y un tratamiento explícito al desbalance mediante oversampling y class weighting. Este enfoque no solo logró el mejor rendimiento (79.62% de accuracy), sino que también solucionó los problemas previamente identificados en las clases 1 y 7, elevando sus métricas generales.

Entonces podemos decir que lo que aprendimos de la implementación de este proyecto es principalmente que:

- Las mejoras arquitectónicas deben acompañarse de estrategias adecuadas de tratamiento de datos
- La bidireccionalidad y profundidad del modelo mejoran la discriminación temporal
- El rebalanceo es fundamental para datasets fisiológicos reales.

Además del aporte técnico, los resultados obtenidos en este proyecto muestran claramente el potencial que tienen los modelos de deep learning en aplicaciones clínicas, biomédicas e incluso industriales basadas en señales EMG. Estas arquitecturas no solo permiten

identificar patrones musculares complejos, sino que también son capaces de hacerlo aun cuando existe ruido fisiológico o variabilidad entre personas, lo cual es una condición típica de este tipo de señales. Gracias a esto, se abren posibilidades reales y muy increíbles para desarrollar sistemas más precisos y accesibles, como prótesis mioeléctricas que respondan mejor al usuario, herramientas de rehabilitación adaptadas a cada paciente, interfaces humano-máquina más intuitivas y mecanismos de control muscular para robótica asistiva [3] [4] [5].

Mejorar la precisión y robustez en la interpretación de señales EMG no es solo un avance técnico: tiene un impacto directo en el diseño de dispositivos más seguros, funcionales y confiables, y en la creación de tecnologías de apoyo que pueden transformar la calidad de vida de muchas personas. La combinación deep learning y las señales biomédicas es muy interesante ya que pueden combinarse para generar beneficios reales a nivel social y tecnológico.

Referencias

- [1] Krilova, N., Kastalskiy, I., Kazantsev, V., Makarov, V., & Lobov, S. (2018). EMG Data for Gestures [Dataset]. UCI Machine Learning Repository. <https://doi.org/10.24432/C5ZP5C>.
- [2] CNN-LSTM model for Time Series Forecasting. (n.d.). EmergentMind. <https://www.emergentmind.com/topics/cnn-lstm-model-for-time-series-forecasting>
- [3] De Jonge, S., Potters, W. V., & Verhamme, C. (2024). Artificial intelligence for automatic classification of needle EMG signals: A scoping review. *Clinical Neurophysiology*, 159, 41–55. <https://doi.org/10.1016/j.clinph.2023.12.134>
- [4] Meta. (n.d.). EMG Wristbands and Technology. Meta Emerging Tech. <https://www.meta.com/emerging-tech/emg-wearable-technology/>
- [5] Joshi, D. C., Kumar, P., Joshi, R. C., & Mitra, S. (2024). AI-enhanced analysis to investigate the feasibility of EMG signals for prosthetic hand force control incorporating anthropometric measures. *Prosthesis*, 6(6), 1459–1478. <https://doi.org/10.3390/prosthesis6060106>